

# **Středoškolská odborná činnost**

**Obor:** 17. Filozofie, politologie a ostatní humanitní a společenskovědní obory

**#filterbubble**

**Autoři:** Františka Sandroni  
Jakub Dostál

Olomouc 2017

## **Poděkování**

Rádi bychom poděkovali Dott. Kvidu Sandroni za projevené pozorné připomínky během celé tvorby naší práce, každá sebemenší myšlenka nám byla cennou radou a podnětem ke zdokonalování studie. Velký dík patří také Barboře Pomykalové za grafickou úpravu. Neméně děkujeme všem, kteří se ochotně podíleli na korektuře práce.

Prohlašujeme, že jsme tuto práci vypracovali samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů.

Prohlašujeme, že tištěná verze a elektronická verze soutěžní práce SOČ jsou shodné.

V Olomouci dne .....

.....

**Title:** #filterbubble

**Authors:** Františka Sandroni, Jakub Dostál

**School:** Slavonic grammar school Olomouc

**Abstract:**

Nowadays one of the mostly used source of the information are social networks. But the content user watches is adjusted by *preferential algorithms*. They filter information and lead one to situation, when the content he wathes is nott fully balanced. The communities are constituted from the people with same initial opinion. This phenomena is called the *filter bubble* and it causes [[[can cause (zalezi na tom co chceme skutecne rict)]]] creation of the extremism in the population, because it avoids users to see wide variety of opinions. And furthermore confirms the user that his opinion is the only opinion by shoving him lot of content with same orientation.

We introduce the filter bubble and it's positives and negatives firstly. We present new methodology of filter bubble studying on the data from the *Twitter* afterwards. The data are collected and then processed by the *sentimental analysis*. In contrast to state of the art researche we are using with larger number of subjects directly from Twitter. At the end we show positive and negative features of the new methodology on few examples.

[[[pokud budeme mluvit i o tom, ze trump ib nevytvari, musime pridat neco na konec abstraktu]]]

**Keywords:** filterbubble, social media, sentiment analysis, democracy, society

**Název práce:** #filterbubble

**Autoři:** Františka Sandroni, Jakub Dostál

**Škola:** Slovanské gymnázium Olomouc

**Abstrakt:**

Významným zdrojem informací v dnešní době jsou sociální sítě. Obsah, který na nich jedinec pozoruje je však ovlivňován *preferenčními algoritmy*. Ty filtrují informace a vedou jedince do situace, kdy okruh příspěvků, které pozoruje, není plně vyvážený. Tím pádem se zde vytvářejí komunity, jež výrazně modifikují objem a obsah informací ovlivňující jejich členy. Tomuto fenoménu se říká *filter bubble* a může vést například k samovolnému vzniku extrémistických názorů a skupin, neboť jedinci v dané bublině nemají přístup k dostatečně širokému spektru informací, ale pouze k zúženému výběru.

Práce nejprve představuje *informační bublinu* a její positiva a negativa. Poté prezentujeme novou metodiku výzkumu informační bubliny na datech poskytovaných *Twitterem*. Tato data jsou nejprve pečlivě vybrána a následně zpracovávána pomocí *sentimentální analýzy*. Narozdíl od mnoha předešlých studií pracujeme s větším počtem subjektů a jejich konkrétním chováním na sociální síti. Funkčnost našeho modelu ukážeme na několika jednoduchých příkladech, na nichž představíme jejich kladné i záporné vlastnosti.

**Klíčová slova:** informační bublina, sociální sítě, sentimentální analýza, demokracie, společnost

# Obsah

<b>1</b>	<b>Co před námi internet skrývá</b>	<b>3</b>
1.1	Filter bubble . . . . .	3
1.2	Problémy filter bubble . . . . .	4
1.3	Výhody filter bubble . . . . .	5
1.4	Preferenční algoritmy . . . . .	6
<b>2</b>	<b>Metody sběru dat</b>	<b>7</b>
2.1	Twitter . . . . .	7
2.2	Data z Twitteru . . . . .	8
2.3	Sentimentální analýza textu . . . . .	8
2.4	Technické detaily sentimentální analýzy textu . . . . .	9
<b>3</b>	<b>Konstrukce měření</b>	<b>10</b>
3.1	Sběr dat . . . . .	10
3.2	Pozorování efektů informační bubliny . . . . .	11
3.3	Výběr pozorovaných skupin . . . . .	12
<b>4</b>	<b>Diskuze měření</b>	<b>13</b>
4.1	Klíčové slovo: potrat . . . . .	13
4.2	Klíčové slovo: Trump . . . . .	15
<b>5</b>	<b>Závěr</b>	<b>16</b>
	<b>Reference</b>	<b>17</b>

# Úvod

Sociální sítě se čím dál více dostávají do popředí nejen jako volnočasové platformy pro různé aktivity, ale i jako informační kanály. V tomto ohledu se transformují ve zdroj aktuálních zpráv z celého světa bez ohledu na to, zda jde o novinku z uměleckých sfér, výsledky vědeckého zkoumání či seriózní informace z problematiky politických vztahů.

Aby uživatelé mohli sledovat jim imponující obsah, existují na sociálních sítích softwary umožňující filtraci uživatelem viděných příspěvků, nazývají se *preferenční algoritmy*. Personalizace informačního kanálu vytváří kolem uživatele okruh pro něj obsahově zajímavých příspěvků, což v důsledku může vést do situace, kdy je obklopován stále stejnými myšlenkami a názory. Tento fenomén byl nazván *filter bubble*, neboli *informační bublina* a je doposud nepříliš prozkoumaným jevem ve společnosti. Většina studií primárně pojímá filter bubble jako fenomén na úrovni sociologie a psychologie studující ho svými tradičními postupy.

Cílem naší práce je vyvinutí nové metody studia filter bubble, která by umožnila sledovat míru postižení konkrétních skupin ve společnosti. Abychom mohli informační bublinu studovat ve velkém měřítku, využijeme poznatků *machine learningu* aplikovaných na data poskytovaná sociální sítí Twitter. Tato data po pečlivé selekci zpracujeme a pomocí *sentimentální analýzy* ilustrujeme rozšíření informační bubliny napříč společností.

Potenciálem naší metody je její využití v sociologickožurnalistické sféře, kde by mohla pomoci řešit zásadní otázky v oblasti informovanosti společnosti a také expanzi ideologických názorů.

# 1 Co před námi internet skrývá

Ve světě plném technického pokroku a masového používání internetu se snadno můžeme ztrácet v množství přijímaných informací. Nepřeborné množství zdrojů nás dennodenně zahlcuje spoustou nových zpráv ať už na sociálních sítích či kdekoli jinde. Každá nově získaná informace rozšiřuje a formuje naše myšlenky. Co se však stane, získáváme-li stále stejné typy zpráv s obsahem podobným sobě navzájem?

Dostáváme se do tzv. *komnaty ozvěn*, jež nás stálým obklopováním a opakováním stejného názoru žene k radikalizaci nás samých z přesvědčení, že náš názor je ten nejlepší a také z důvodu, že ostatní jinak formulované náhledy na dané téma byly zcela přehlušeny.

Tento problém existuje odnepaměti, jen v jistých ohledech poněkud v jiném formátu. V minulosti nebyli lidé tak silně propojeni jako dnes, proto šíření informací probíhalo v mnohem menším měřítku.

Chodili do stejné hospůdky, navštěvovali jednoho mlékaře, znali jednu švadlenu. To je vedlo k přesvědčení, že právě jimi vybrané hospůdky, mlékaři i švadleny jsou těmi nejlepšími a postupy, jimiž se daní lidé řídili, byly jediným správným řešením. Prakticky nebylo ani jiného řešení, neboť v dosahu nebyl nikdo, kdo by je přesvědčil o opaku, a i kdyby se někdo takový vyskytl, nebyl by se svým novým odlišným stanoviskem přijat mezi komunitu lidí s identickým názorem.

Dnešní společnost není příliš odlišná od té výše popsané, jen nás a naše přesvědčení utváří sociální sítě jako například Facebook a Twitter, fungující na rychlém tweetování zpráv. Na jejich zdech sledujeme mnohé odkazy na komentáře, videa a články, formující se názory jedinců i davů, vznikající i zanikající politické myšlenky. Otázkou tedy zůstává, nakolik my sami jsme pohlceni vlastním přesvědčením v oboru a kde a jakým způsobem nás ovlivňují sociální sítě. Zda jsou tato samozvaná masmédia relevantní a kde mají své nedostatky, obzvláště v rovnoměrném šíření informací napříč společnostmi, se budeme zabývat dále.

## 1.1 Filter bubble

*Filter bubble* nebo také *informační bublina* je jedním z mnoha fenoménů dnešní doby. Jako první na ni upozornil a popsal ji Eli Pariser [21, 20]. Jde o jev vyskytující se na sociálních sítích, kdy uživatel každou online aktivitou<sup>1</sup> poukazuje na oblasti jeho zájmů. Tyto algoritmy snažící se usnadnit život pomocí personalizace viděných informací se každou další činností uživatele zdokonalují, což v konečném výsledku znamená, že jsou to právě ony, které rozhodují, co bude pro uživatele viditelné a co naopak konsekvencí prací algoritmů bude uživateli podáno v menší míře, či úplně skryto v celkovém proudu informací [9]. Celkově to tedy může vést jedince do situace, kdy místo širokého spektra příspěvků na sobě obsahově nezávislých, vidí příspěvky jen takové, jež byly vybrány preferenčními algoritmy na základě jeho předešlé činnosti a tedy velmi zúžené škále informací.

Jak se ukázalo v předešlé studii [9], filter bubble je velmi individuální a její efekt není u všech uživatelů zcela totožný. Míra filter bubble nezávisí pouze na obsahu viděných příspěvků, jak by se mohlo předpokládat, avšak na zdroji odkud informace čerpá. V důsledku můžeme pozorovat značně silnější efekt informační

---

<sup>1</sup>Tím rozumějmě kliknutí, sdílení, komentování a obdobné činnosti.

bublina u uživatelů s mnoha konexemi na jiné uživatele, než u těch s menším rozsahem jejich spojení. Vycházíme-li z reálného prostředí, všimáme si, že jedinci s mnoha známostmi mají silnější postavení ve společnosti a tudíž i notný vliv na ostatní členy dané společnosti. Stejně tak je tomu na sociálních sítích. V situaci, kdy uživatel s mnoha konexemi na ostatní projeví svůj názor, příspěvkem či komentářem, je tu daleko větší pravděpodobnost ovlivnění značného množství uživatelů s ním spojených.

Informační bublina je velmi rozšířeným problémem, pokud si ji je však uživatel vědom, není filter bubble nepřekonatelnou bariérou v získávání relevantních informací.

## 1.2 Problémy filter bubble

Vezmeme-li v úvahu, kolik času lidé tráví na sociálních sítích, je zřejmé, že jejich názory a postoje se primárně vytvářejí zrovna zde [9, 12, 22]. Sleduje-li uživatel pouze názorově shodné příspěvky, mohla by informační bublina představovat značnou hrozbu demokratickým systémům, neboť uživatelům předkládá již vyfiltrované příspěvky a to zejména takové, jež by podpořily názor uživatele samotného, nikoli názor odlišný.

V jedné z předešlých studií [12] byla provedena řada experimentů odhalujících několik zajímavých efektů informační bubliny. Jako mnoho podobných studií však své výsledky vyvozuje z reakcí malého počtu lidí<sup>2</sup> v uměle vytvořených situacích. Ukazují například, že přijímání názorů z různých úhlů pohledů závisí především na hloubce zájmu o dané téma. Čím vyšší je zájem o téma, tím vyšší je ochota přijímat protiargumenty, a naopak čím nižší je zájem o téma, tím nižší je ochota přijímat protiargumenty.

V případě, kdy jedinec s nízkým povědomím o daném tématu se dostane ke zdroji informací a není motivován hlubším podnětem jako jsou například blížící se volby, nevykazuje zájem o hledání relevantních faktů, nýbrž dává přednost vyhledávání *users opinion* nehledě na zdroje, o které se *users opinion* opírá. Předložíme-li tedy současně jedinci informace podobné jeho již dříve získaným postojům a informace lišící se od jeho postoje, ve většině případů si vybere informace podobající se jeho stanovisku, avšak dostane-li se jedinec s nízkým povědomím do kritické situace<sup>3</sup> a je motivován se v daném tématu vzdělávat, začíná vyhledávat informace podložené fakty, ať už podporující jeho stanovisko, či nikoliv.

Takovéto chování stále se opakujícího výběru již známého obsahu může jedince vést do *echo chamber*, kde tímto selektivním získáním podobně motivovaných informací se utvrzuje ve svém původním názoru a naopak informace odlišné či opačné vytěsňuje do takové míry, že není schopen jejich dalšího vnímání.

Informační bublina může zapříčinit nemalé následky v makroskopickém měřítku na celou dnešní společnost v mnoha ohledech. V první řadě upozorníme na zjevné riziko, které se utváří při aktivních preferenčních algoritmech mezi uživateli sociálních sítí v demokratických společnostech. Zde i přes nabízenou diversitu obsahu uživatel opět vidí jen omezenou část. Autoři v [4] vychází z

---

<sup>2</sup>V konkrétním případě této práce okolo 30 jedinců.

<sup>3</sup>Kupříkladu je-li jedinec postižen nějakou nemocí, je mnohem více motivován vyhledávat informace.



konceptu, kde demokracie jako taková je rozdělena na liberální, deliberativní, republikánskou a agonistickou a pozorují, že každá z nich je ohrožena v jiné části její struktury. Problémy způsobené informační bublinou v liberální demokracii, jakožto ztráta povědomí občanů o různorodosti volby a nezávislosti médií, coby primárního zdroje informací občanů zvrhne upadajícího do rukou úzkého okruhu lidí, a demokracie deliberativní, kde sledujeme nedostatky v rovnocenné občanské diskusi, klesající toleranci vůči odlišným názorům a úbytek obecného přání zisku nových epistemických argumentů, částečně řeší již popsané aplikace jako třeba *Balancer*, *Scoopinion*, *ConsiderIt*, *Opinion space* a další. Žádná však neřeší ohrožení v typech republikánské a agonistické demokracie.

Otázkou proto zůstává, jak dostatečně rozpoznat míru filter bubble a ochránit rozhled uživatele sociálních sítí bez ohledu na charakter demokracie, ve které se vyskytuje. Představme si živé předvolební období, kdy politické strany vytáhnou do boje a nebojí se použít žádných prostředků k potupě politických rivalů, kdy jedna aféra stíhá druhou, a na povrch vyplouvají rozličné skandály představitelů politických stran. Zároveň jsou také vypouštěny různé výstižné slogany rádoby řešící lokální i globální problémy. Čím více zaujatý slogan, tím masovější ovace. Začíná davové šílenství v podobě obrovských internetových diskusí v tématech, jež jsou pro uživatele klíčová. Vyhledáváním a připojováním se ke společenství se jedinec cítí být více informovaný, nicméně ztrácí přehled o celém tématu a zaměřuje se na čím dál menší okruh informací podporující jeho názor. Kamkoli se podívá a cokoli si přečte, je uspokojen, neboť vidí stále příspěvky podobné jeho názorům. Jak je dobře známo, uživatelé těchto internetových diskusí jsou často svým přesvědčením uchvázeni natolik, že ztrácí veškeré zábrany racionálně smýšlející osoby a své zaujaté názory se nebojí ukazovat široké veřejnosti [19]. Je-li však náhled na téma již ze začátku extremistický, kam až může zajít? Co když tyto podporované politické strany proklamující se všeobecnými předsudky nejsou vhodnou volbou pro stát, ale díky svým hojně sdíleným příspěvkům oslovují více a více lidí, kteří dále šíří ideologii? Informační bubliny se z tohoto hlediska stávají problémem, i co se týče jejich etického vlivu na společnost.

### 1.3 Výhody filter bubble

Zkoumáme-li filter bubble jako celek a přestaneme-li se zaměřovat pouze na hrozby, které s sebou přináší, spatřujeme i pozitivní dopady. Kladné využití informační bubliny je zřejmé, zajímáme-li se o nějaké téma do hloubky a nehrozí ztráta objektivitu jedince.

Vezměme si kupříkladu sportovního fanouška zaměřeného pouze na tenis. Neuvěřitelné množství existujících sportů a ještě větší počet příspěvků o nich dennodenně zaplavuje sociální sítě. Z tohoto jasně vyplývá, že kdyby fanoušek tenisu sledoval příspěvky ze všech odvětví sportů, ty o tenise by se mu zobrazovaly výrazně méně, tudíž by teoreticky mohlo dojít k omezení informovanosti ve středu zájmu daného fanouška. V takovém případě by nemusel zaregistrovat všechny výsledky posledních utkání, zprávy o kondici sportovců, či změnu času konání další akce, což by pro fanouška mohlo býti rozhodující.

Stejně tak můžeme pozorovat pozitivní důsledky informační bubliny v podnikatelské sféře. Například takový vlastník restaurací potřebuje být plně informován o všech novinkách ve svém oboru vedoucích k vylepšení pracovních postupů.

Nemálo může filter bubble pomoci, co se konkurenceschopnosti podnikatele týče. V situaci, kdy bude podrobně znát rozsah a celkovou nabídku služeb konkurentů, má mnohem větší šance uspět na trhu práce, což by s primárně zobrazovanými příspěvky o výsledcích šachových turnajů nebo průměrné spotřeby uhlí na jednu domácnost v jeho kanále informací rozhodně nedokázal tak snadno.

Jak vidno, informační bublina, pomineme-li negativní dopady na společnost popsané v předchozí podkapitole, není pouze hrozbou, ale může nám v mnoha ohledech usnadnit orientaci na sociálních sítích, ať jsme již fanoušky sportu, podnikateli, vědci, či kulturními nadšenci.

## 1.4 Preferenční algoritmy

Jak jsme již výše zmínili, personalizace obsahu, který vidíme na internetu, může být jak velkým problémem, tak velkou výhodou. Čemu jsme však dosud nevěnovali pozornost je, jak informační bubliny vznikají. Je zřejmé, že *Facebook*, *Twitter*, *YouTube* a podobné internetové giganty shromažďují velké množství dat o našich internetových aktivitách. Méně jasné je, že to nedělají kvůli zlomyslným plánům na ovládnutí světa, nýbrž kvůli snaze zpříjemnit užívání jejich služeb<sup>4</sup>. Tato data poté pomocí moderních matematických a statistických metod užívají například k výběru obsahu, který nám bude co nejvíce imponovat, respektive k výběru obsahu, o kterém jsme se již dříve vyjádřili, že je pro nás zajímavý.

S obdobným přístupem se můžeme setkat při online nakupování [13], kde jsou nám doporučovány produkty obdobné těm, které jsme v poslední době hledali. Stejně tak například na *YouTube* [6], se dostaneme dříve k videím s podobným obsahem, jaký často sledujeme.

Metody, které se užívají pro sociální sítě a informační kanály [14], jsou většinou velmi sofistikované a opírají se o hluboké znalosti *machine learningu*, *statistiky* a *data miningu*. Velmi zjednodušeně řečeno, nový uživatel určité stránky je nejprve vystaven velmi širokému spektru informací. Někde na serveru provozovatele sítě sedí malá ne příliš chytrá umělá inteligence, která si zapisuje, na co uživatel kliká<sup>5</sup>. Své zápisky následně zpracovává a pomocí těchto zpracovaných poznámek následně odhaduje, co by se danému uživateli mohlo líbit.

---

<sup>4</sup>Tím, že nám usnadní a zpříjemní jejich užívání, si zajistí větší návštěvnost, což je zdrojem jejich příjmů.

<sup>5</sup>Samozřejmě také sleduje další způsoby hodnocení příspěvků, které jsou pro různé stránky odlišné. Na *Facebooku* například *like*, na *Twitteru* *retweet*.


## 2 Metody sběru dat

S pokrokem v oblasti technologie probíhá i obrovský pokrok v oblasti čerpání zpráv a informací. Narozdíl od minulosti drtivá většina obyvatel vyspělých států má přístup k aktualitám v průběhu celého dne. Denní počet příspěvků na *Twitteru* dosahoval v roce 2010 neskutečných 6 milionů [15]. Je zřejmé, že není možné používat stejné postupy pro analýzu takto rozsáhlého množství dat jako dříve. Naštěstí se již nějakou dobu významným tempem posouvá i oblast *Big Data*, *Machine Learningu* a jejich podoblastí. Tyto obory nacházejí uplatnění téměř ve všech oblastech dnešní vědy [11] a stále větší pozornosti se jim dostává i v sociologii [26, 16, 25].

### 2.1 Twitter

*Twitter* je sociální síť se strukturou přátelských vztahů odlišnou od *Facebooku*. Uživatel si může navolit téměř libovolné množství lidí, jejichž příspěvky se mu budou zobrazovat. To však neznamená, že lidem, které si navolil, se budou zobrazovat jeho příspěvky.

Pro jednoduchost uveďme příklad. Pepa je nový uživatel *Twitteru*. Jeho kamarád ze školy se jmenuje Jiří a politik, kterého viděl včera ve zprávách a zamlouval se mu, má jméno Alois. Pepa začne *sledovat*<sup>6</sup> jak Jiřího, tak Aloise. Od té chvíle uvidí všechny příspěvky, jak od spolužáka Jiřího, tak od politika Aloise. Za nějaký čas začne i Jiří *sledovat* Pepu. Od té chvíle i Jiří uvidí všechny Pepovy příspěvky. Politik Alois však Pepu nezná, proto ho *sledovat* nezačne, a tedy neuvidí příspěvky sdílené Pepou. Tyto vztahy jsou přehledně zobrazeny v grafu Obr. 1.



**Obrázek 1:** Znázorněné šipky směrem k vcholu *Pepa* ukazují ostatní uživatele, jimiž je *Pepa* ovlivněn. Je tedy patrné, že *Pepa* a *Jiří* vidí své příspěvky navzájem a navíc vidí i příspěvky *Aloisovi*. *Alois* však nevidí ani příspěvky *Pepa*, ani *Jiřího*, neboť příspěvky od těchto dvou uživatelů neproudí směrem k *Aloisovi*.

Takovouto strukturu můžeme chápat jako orientovaný graf, kde vrcholy představují uživatele *Twitteru* a orientované hrany mezi nimi proud příspěvků, tedy vztah *following*, neboli *sledující*. Pokud uživatel sleduje mnoho lidí, je směrem k němu připojeno více hran, mluvíme o uživateli s vysokou konektivitou nebo s vysokým stupněm. Obdobně uživatel, který má malou konektivitu, je takový, k němuž směřuje málo hran, je málo *sledován*.

<sup>6</sup>Jde přímo o pojem *following* z této sociální sítě, něco jako *přátelství* na Facebooku.

Příspěvky na *Twitteru* mohou mít jakýkoliv textový tvar do délky 140 znaků, doplněný obrázkem nebo videem, mnohdy také hypertextovým odkazem na externí článek. Obrázky, videa, ani články na jiných stránkách nejsme schopni analyzovat. Plně však zkoumáme textovou část příspěvků. Ty bývají doplněné o tzv. *hashtagy*. To jsou slova nebo krátká spojení slov, před kterými stojí znak # (křížek). Z pravidla se jedná o slova, která jsou velmi aktuální, například různé reference na současné politické dění a podobně. Mnohdy jsou *hashtagy* užívány pouze pro zvětšení popularity příspěvku, jelikož častá forma vyhledávání je právě pomocí *hashtagů*.

## 2.2 Data z Twitteru

Právě data z *Twitteru* jsou pro nás velmi vhodná. Jak se ukazuje [2], narozdíl od *Facebooku*, *Twitter* užívá mnoho uživatelů jako zdroj informací a zpráv o aktuálním dění ve světě. Samozřejmě můžeme zpochybňovat validitu a přesnost informací, které se na takovýchto sítích objevují. Ať už jsou takovéto obavy oprávněné nebo ne, výzkum sociologických jevů, který v této práci provádíme, to nijak neovlivňuje.

Dalším důležitým důvodem, který vedl k výběru *Twitteru* jako média, ze kterého budeme stahovat informace, je snadná přístupnost k datům pomocí služby API poskytované přímo *Twitterem* [27]. Konkrétně pro naše účely jsme tuto službu nepoužívali přímo, ale za pomocí balíčku *tweepy* [10] pro programovací jazyk *python*. Ten umožňuje velmi snadné ovládání a filtrování proudu dat, které si vyžádáme z *Twitteru* a také jejich okamžitou analýzu a zpracování v *pythonu*.

## 2.3 Sentimentální analýza textu

Jednou z velice rozvinutých oblastí machine learningu, je tzv. *sentimentální analýza textu*, což je forma zpracování přirozeného jazyka<sup>7</sup> [3]. V základní a nejvíce studované verzi tohoto problému se snažíme naučit počítač odhadnout, jestli je věta *pozitivní* či *negativní*. Existují samozřejmě i obdobné úlohy. Můžeme se zajímat o rozdíl mezi větami psanými *objektivně* a *subjektivně*, nebo rozlišovat více než dvě kategorie, například rozlišovat texty napsané *rozčilleně*, *smutně*, *radostně* a *překvapeně*. Záleží pouze za jakým účelem problém řešíme a datech, které máme k dispozici.

Sentimentální analýza textu se skládá z několika základních kroků, které jsou v obecném měřítku velmi podobné jiným machine learning algoritmům. Základem jsou data. V našem konkrétním případě se jedná přibližně o 1.5 miliónů tweetů<sup>8</sup> v anglickém jazyce, které jsou označeny lidmi jako pozitivní, nebo negativní. Algoritmus, který používáme, je neuronová síť [24] obohacená o takzvané *word embedding* vrstvy a *convolution* vrstvy. Takovýto model je nejdříve "natrénován"<sup>9</sup> na

<sup>7</sup>Pro pojem zpracování přirozeného jazyka budeme užívat převážně zkratku NLP z anglického názvu *Natural Language Processing*

<sup>8</sup>Uspořádaných ve velkém datasetu složeném z několika menších [23, 28].

<sup>9</sup>Tréninkem je v této oblasti většinou myšlena optimalizace vhodně zvolené funkce, která odráží přesnost modelu.

označených datech<sup>10</sup>. Poté je možné ho snadno a s mnohem nižší časovou komplexitou, než byla zapotřebí při tréninku, používat pro predikci sentimentu z textu. Výstupem takového modelu je pravděpodobnost, že předložený text je pozitivní, tedy reálné číslo mezi 0.0 a 1.0. Takové číslo můžeme chápat jako míru positivity sentimentu textu. Tedy je-li tweet ohodnocen číslem 0.0, je zřejmé, že je negativní. Je-li ohodnocen číslem 0.5, chápeme ho jako neutrální. Text ohodnocený číslem 1.0 je jistě pozitivní.

Pokud řekneme, že při měření bylo zjištěno, že za určitou dobu bylo v určité skupině 40 % lidí proti a 60 % pro, je tím myšleno, že 40 % tweetů mělo sentiment menší než 0.5 a naopak 60 % větší než 0.5.

## 2.4 Technické detaily sentimentální analýzy textu

Pohlédneme-li do větších detailů našeho modelu na odhad sentimentu, prvním krokem po získání datasetu je vytvořit slovník s  $V = 5000$  nejčastějšími slovy. Poté je každý datový bod, tedy každý *tweet*, transformován ze seznamu slov do seznamu *1-hot-encoding* vektorů<sup>11</sup>.

Následuje *word embedding* vrstva [17, 8], která vytvoří novou reprezentaci slov. Ta je schopná mnohem lépe zachovávat semantické vlastnosti jednotlivých slov<sup>12</sup>. Vektory s dimenzí  $V = 5000$  transformuje do vektorů s dimenzí  $N = 32$ , které se mnohem lépe hodí pro zpracování a sentimentální analýzu, protože lépe reprezentují skutečný význam slov.

Na tuto vrstvu navazuje *convolution* vrstva [29], která je schopná prozkoumat postavení slov ve větě. Následuje *fully connected* vrstva, která slouží ke správné interpretaci vlastností odvozených neuronovou sítí, ukončená *relu* aktivační jednotkou. Ta se stará o dodání nelinearity do modelu, což zajišťuje přesnější klasifikaci. Úplně poslední je další plně propojená vrstva zakončená aktivační funkcí *sigmoid*, která se postará o transformaci na pravděpodobnost, pro snazší budoucí interpretaci.

Zdrojový kód pro sentimentální analýzu byl napsán v programovacím jazyce *pythonu*, za užití balíčků *TensorFlow* [1] a *Keras* [5].

---

<sup>10</sup>Data, u kterých označil jejich sentiment reálný člověk, považujeme za správná. I to je však relativní. Necháme-li více lidí ohodnotit ta stejná data, zjistíme, že ani lidé nejsou v hodnocení příliš konzistentní [18]. Pro naše účely je to však naprosto dostačující.

<sup>11</sup>Kde každý vektor je reprezentací jednoho slova. Takové reprezentace mají velmi jednoduchý a zároveň velmi nepraktický tvar. Je-li slovo ve slovníku na  $k$ -té pozici, bude jeho *1-hot-encoding* reprezentací vektor plný nul, až na  $k$ -tou pozici, kde se bude nacházet číslo 1. Každé slovo je tedy reprezentováno vektorem s dimenzí 5000. Je zřejmé, že tato reprezentace není příliš efektivní.

<sup>12</sup>Na takové reprezentaci slov můžeme sledovat zachování semantických vlastností a dokonce i možnost heuristického užití aritmetiky. Můžeme si všimnout, že například  $\text{vec}(\text{France}) - \text{vec}(\text{Paris}) + \text{vec}(\text{Italy}) \approx \text{vec}(\text{Rome})$ . Takové vlastnosti jsme při užití *1-hot-encoding* pozorovat nemohli.

### 3 Konstrukce měření

Sentimentální analýza textu nám umožňuje automaticky ohodnotit mírou sentimentu u velkého množství textových příspěvků. Výsledkem takového ohodnocení je však pouze reálné číslo mezi nulou a jedničkou. Proto odtud nevede žádná přímá cesta k měření síly informační bubliny na částech společnosti.

Uvažujeme-li konkrétního jedince ve společnosti, informační bublina není nijak explicitně závislá na něm samotném. Místo toho je až implicitně závislá na osobách, které tvoří obsah viditelný námi studovaným jedincem. Proto je zřejmé, že budeme-li chtít pozorovat sílu a efekt informační bubliny na konkrétního jedince, předmětem našeho studia musí být lidé v okolí tohoto jedince. V případě sociálních sítí to musí být konkrétně příspěvky, které tyto lidé tvoří.

Jak jsme již zmiňovali v předešlých kapitolách, pro účely našeho výzkumu jsme využili sociální síť *Twitter*. Ta se v poslední době transformuje spíše do podoby informačního kanálu [2]. Neméně důležitý je fakt, že umožňuje poměrně snadný přístup k datům [10, 27].

#### 3.1 Sběr dat

Naším cílem je pozorovat efekty a sílu informační bubliny na vybrané skupině ve společnosti. V odstavcích výše jsme však shrnuli, proč to není vůbec přímočarý proces.

Abychom vybrali určitou skupinu uživatelů *Twitteru* co nejpřesněji, využijeme existujících stránek, které sdružují příznivce hledané skupiny. Chceme-li například studovat, jak jsou informační bublinou postiženi *biochemici*, vybereme je z lidí, kteří sledují *Twitterový* profil *Biochemical Society*. Ten se po našem průzkumu *Twitteru* ukázal jako nejvíce populární účet s tímto tématem, sleduje ho přibližně 15 tis. lidí. Služby poskytované *Twitterem* na stahování dat nás bohužel omezují v počtu zkoumaných uživatelů, proto musíme ze všech 15 tisíc vybrat pouze část. Abychom zajistili náhodnost tohoto procesu, o výběr podmnožiny se stará jedna část softwaru [7], který jsme pro tyto účely vytvořili.

Nyní máme vybranou skupinu vzorků, na kterých chceme pozorovat efekty informační bubliny. Ta je však závislá na uživatelích, kteří vytvářejí obsah viditelný studovanými lidmi. To jsou ti uživatelé, které studované subjekty sledují. Vybereme-li několik *biochemiků*, na kterých chceme sledovat informační bublinu. Nyní musíme studovat obsah, který tvoří uživatelé sledovaní *biochemiky*.

Pro přehlednost tyto vztahy vyjádříme matematicky. Je-li  $\mathbb{M}_{bio}$  množina všech uživatelů, kteří sledují stránku *Biochemical Society*, našim prvním úkolem je náhodně vybrat podmnožinu  $\mathbb{P}_{bio}$  takovou, že obsahuje námi zvolený počet prvků  $|\mathbb{P}_{bio}| = n$  a zároveň každý prvek je vybrán s pravděpodobností  $p = \frac{1}{|\mathbb{M}_{bio}|}$ . Nyní pomocí služeb poskytovaných *Twitterem* vybereme množinu  $\mathbb{S}_{bio}$  takovou, že každý prvek je sledován alespoň jedním prvkem z  $\mathbb{P}_{bio}$ . Je-li  $\mathbb{T}$  množina všech uživatelů *Twitteru* a  $\mathbb{A}$  tzv. *adjacency matrix* celého *Twitteru*, tedy matice, pro kterou platí:

$$A_{ij} = \begin{cases} 1, & \text{pokud } j \text{ sleduje } i; \\ 0 & \text{jinak.} \end{cases} \quad (3.1)$$

Potom  $\mathbb{S}_{bio} = \{k \text{ takové, že } \exists l \in \mathbb{T} : A_{kl} = 1 \wedge l \in \mathbb{P}_{bio}\}$ .



### 3.2 Pozorování efektů informační bubliny

Na takto vybrané skupině lidí  $S_{bio}$ , které sledují uživatelé, jejichž informační bublina nás zajímá, chceme pozorovat, zda jsou zaměřeni pouze jedním směrem a nepodávají dostatečně široké spektrum názorů. Umíme však pouze odhadnout sentiment jakéhokoliv *tweetu*.

Po dobu měření budeme stahovat všechny tweety, které vytvoří uživatelé z  $S_{bio}$ , tedy lidé, které sledují subjekty našeho zájmu. Zajímají-li nás efekty filter bubble na *biochemiky* budeme stahovat všechny tweety, které vytvoří lidé, sledovaní *biochemiky*<sup>13</sup>.

Ze všech takto stažených tweetů vybereme pouze ty, které obsahují, námi zvolené klíčové slovo. Mohli bychom použít například slovo „*Trump*“. Tím dostaneme pouze tweety, které se zabývají něčím ve vztahu k prezidentu *Trumpovi*. Pro každý takto vyfiltrovaný tweet provedeme sentimentální analýzu a tím odhadneme, zda má autor pozitivní nebo negativní vztah k danému tématu. Provedeme-li takováto měření na dvou odlišných skupinách a stejném klíčovém slově, tedy konkrétním tématu, můžeme odhadovat, kde působí informační bublina. Ať už téma podporuje, či nikoliv. Například můžeme porovnávat rozložení sentimentu zpráv s klíčovým slovem „*Trump*“, které vidí *biochemici* a příznivci *těžby ropy*. Můžeme předpokládat, že *biochemici* budou žít v bublině, která má více negativní názor na prezidenta *Trumpa* a příznivci *těžby ropy* naopak.

Člověku se může zdát, že tímto pouze pozorujeme názor, který mají *biochemici* na *Trump*. Tak to ale zdaleka není. Ve skutečnosti zkoumáme, jaké zprávy jsou viditelné *biochemiky*. A právě zprávy nimi viditelné jsou zdrojem informační bubliny, kterou chceme popisovat.

Zde je potřeba podotknout, že skupiny a klíčová slova se musí volit velmi pečlivě. Vybereme-li klíčové slovo „*Islámský stát*“ a pozorujeme sentiment, může dojít k velkému nedorozumění. Tweet, který hovoří o činech páchaných *Islámským státem* bude jistě negativní. Problém však nastává v případě, kdy nějaký tweet hovoří například o vítězství nad *Islámským státem*. Text takového příspěvku se snadno může jevit jako pozitivní<sup>14</sup>, což bychom špatně vyhodnotili jako tweet podporující *Islámský stát*. Proto je potřeba jak pozorované skupiny, tak klíčová slova volit velmi pečlivě.

V neposlední řadě zmiňme, že data stahovaná z Twitteru jsou již filtrována preferenčními algoritmy. Analyzované příspěvky jsou jen ty, které splňují námi zadané požadavky a zároveň se objevují na předních pozicích informačních kanálů sledovaných uživatelů<sup>15</sup>. Podotkneme, že toto chování je pro náš výzkum velmi užitečné, ne-li klíčové. Pokud bychom stahovali všechny příspěvky, i ty, které se objeví až ve velmi spodní části informačních kanálů, kde je již uživatel nemá šanci zaznamenat, nemohli bychom informační bublinu studovat.

V souvislosti s tímto vyvstává ještě jedna záležitost, která by mohla být zdrojem nedorozumění. Pro kvalitní vysvětlení, předběhneme strukturu naší práce

<sup>13</sup>Ve výsledku tedy budeme stahovat všechny tweety, které *biochemici* uvidí, což je právě náš záměr.

<sup>14</sup>To však není problémem počítače, který text analyzuje. I člověk by radostný tweet o vítězství označil jako pozitivní.

<sup>15</sup>Vyvstává otázka jak moc musí být příspěvek sdílený na to, aby byl považován za dostatečně známý a my ho analyzovali. O toto se automaticky starají preferenční algoritmy Twitteru [27], které jsou námi nastavené na úroveň *medium* což je nepřísnější nám poskytovaná úroveň filtrace.

uved'me příklad. Jednou z pozorovaných skupin je skupina *feministek* s klíčovým slovem „*abortion*“. Porovnáme-li nalayzovaná data této skupiny s daty s příspěvků z celého *Twitteru*<sup>16</sup> zjistíme, že tweetů viditelných *feministkami* je podstatně více než tweetů viditelných celým *Twitterem*. Co se může zdát naprosto nesmyslné. Vždyť skupina *feministek* je jistě podmnožina celého *Twitteru*, proto by počet příspěvků s daným klíčovým slovem měl být podstatně menší. Ve skutečnosti nám však toto říká, že počet velmi sdílených příspěvků s daným klíčovým slovem je větší u *feministek* než u náhodného uživatele *Twitteru*.

### 3.3 Výběr pozorovaných skupin

Pro naše měření jsme provedli důkladný výběr studovaných objektů vycházející z nejaktuálnějšího politického dění, abychom dosáhli co nejpřesnějšího zachycení veškerých možných skupin názorů.

Z důvodu fungování naší metody v anglickém jazyce jsme nevolili témata lokální, kupříkladu z české politické sféry, jež by svým rozsahem a především jazykem nevyhovovala měření, nýbrž zvolili jsme témata globálního rozsahu řešící se na sociálních sítích zejména v anglickém jazyce.

Jako velmi rozporuplnou a politicky zajímavou veřejně známou osobností jsme vybrali nedávno zvoleného prezidenta Spojených států amerických Donalda Trumpa. Nynější prezident Trump byl již ve své předvolební kampani zastáncem silné ekonomiky státu, heslo „*Make America Great Again*“ a příslib zlepšení celkové finanční situace musel velice imponovat nižší a střední vrstvě společnosti. Z tohoto důvodu se nám společnost *příznivců těžby ropy* zdála být optimální volbou.

Jak se také Trump ve svých výrocích zmínil, hodlá snížit dotace na rozvoj vědy, proto usuzujeme, že právě vědecká společnost *biochemiků* bude mít názor na prezidenta Trumpa poněkud negativnější než názor příznivců *těžby ropy*. U těchto dvou skupin jsme proto vybrali jako klíčové slovo heslo „*Trump*“.

Námi druhé zvolené heslo „*abortion*“<sup>17</sup> má také co dočinění s americkou politickou sférou. Trump se jako silný republikán a zastánce progresivního státu s přáním stále rostoucího počtu amerických obyvatel vyjádřil velmi negativně o problematice potratu. Zmínil se o celoplošném zákazu potratů v USA, což vzbudilo v obyvatelstvu silné emoce, a to jak pozitivní, tak negativní.

Velký potenciál, co se týče příznivců potratů, jsme spatřovali v liberálnějších skupinách, které podporují velkou svobodu volby nejen politickou, ale i morální. Proto jsme vybrali *LGBT foundation* s názory liberálnějšími a poté také feministickou skupinu *Everyday Feminism*, jež tradičně podporuje rovnoprávnost žen ve všech oblastech společnosti.

Na rozdíl od těchto dvou podskupin potenciálních sympatizantů s potraty jsme vyhledali skupinu lidí s přísnějšími etickými zásadami. Pro tyto účely byly zvoleny křesťanské komunity *Catholic News Svc* a *Only Mormons*, u nichž bychom mohli očekávat názory na téma potrat mnohem negativnější, než u předchozích dvou.

<sup>16</sup>Tedy s příspěvků, které nejsou nijak omezeni skupinou, která je vidí.

<sup>17</sup>Slovo, jež v angličtině znamená „*potrat*“.




## 4 Diskuze měření

Pozorované skupiny jsme vybírali tak, abychom mohli pozorovat co nejsilnější efekty informační bubliny. Sledované komunity se tedy liší názorem na dané pozorované téma. Je klíčové pochopit, že našim cílem není ukázat to, že mají jiný názor. Cílem je prezentovat rozdílnost v příspěvcích, které na sociální síti členové komunit vidí. Pomocí našich výsledků poté okomentovat jak moc je ohrožena objektivita uživatelů sociálních sítí.

### 4.1 Klíčové slovo: potrat

Začneme s případem, kdy jsme se zabývali diversitou názorů na „*potrat*“. Hledali jsme příspěvky s klíčovým slovem „*abortion*“ a sledovali, zda se sentiment takovýchto příspěvků liší v různých skupinách<sup>18</sup>. Předpokládali jsme, že *katolíci* a *mormoni* budou spíše proti potratům, jejich sentiment bude tedy spíše nižší. Narozdíl od toho u *feministek* a uživatelů sledujících *LGBT foundation* jsme očekávali vyšší sentiment. Tyto skupiny jsme následně porovnávali i se sentimentem a frekvencí příspěvků s tímto klíčovým slovem na celém Twitteru.



(a) Všechny skupiny krom *Everyday Feminism*. (b) *Everyday Feminism* a *Catholic News Svc*

**Obrázek 2:** Histogramy počtu tweetů u skupin s klíčovým slovem „*abortion*“.

Na obrázcích Obr. 2 vidíme histogramy<sup>19</sup> sentimentu příspěvků uvedených skupin. Měření probíhalo v době od 18.03.2017 17:00 do 19.03.2017 08:00.


Překvapivě, z obrázku Obr. 2(a) jde vidět, že tři skupiny *Catholic News Svc*, *Only Mormons* a *LGBT foundation* mají rozdělení identické s průměrem na celém Twitteru. Rozdělení sentimentu i počty příspěvků s tímto tématem jsou naprosto shodné. Toto zjištění pro nás bylo poměrně překvapující. Můžeme říct, že komunity *Catholic News Svc*, *Only Mormons* a *LGBT foundation* se v diskuzi okolo *potratu* dostanou k obsahu, který je v rámci Twitteru absolutně vyvážený.

Na rozdíl od toho, podíváme-li se na histogram Obr. 2(b) zobrazující rozdělení sentimentu u skupin *Catholic News Svc* a *Everyday Feminism* vidíme obrovský

<sup>18</sup>Konkrétně šlo o *katolíky* sledující skupinu *Catholic News Svc*, *mormony* sledující skupinu *Only Mormons*, *feministky* sledující skupinu *Everyday Feminism* a uživatele sledující skupinu *LGBT foundation*.

<sup>19</sup>Na svislé ose je v tomto případě vždy počet příspěvků s příslušnou naměřenou hodnotou sentimentu, která je vyznačena na vodorovné ose. Toto zobrazení nám umožňuje snadno nahlédnout na rozdělení sentimentu v příspěvcích i na počty příspěvků s daným tématem.

rozdíl<sup>20</sup> v samotném počtu často sídlených tweetů s tématem *potratu*. Už tento fakt naznačuje poměrně silnou informační bublinu, ve které jsou pohlceni členové komunity *Everyday Feminism*. Abychom mohli prostudovat i rozložení sentimentu



**Obrázek 3:** Normalizované rozdělení sentimentu příspěvků, které vidí komunity *Catholic News Svc* a *Everyday Feminism*.

a nejenom počet příspěvků vztahujících se k danému tématu, pohlédneme na histogram Obr. 3, který zobrazuje normalizované<sup>21</sup> rozdělení zmíněných dvou skupin.

Při porovnání komunity *Everyday Feminism* a komunity *Catholic News Svc*, která v daném tématu není nijak postižena informační bublinou vidíme markantní rozdíl. Vidíme, že v levé části, kde jsou hodnoty sentimentu menší než 0.5 lehce převažují příspěvky, které vidí komunita *Catholic News Svc*. Kdežto v pravé části, kde jsou zobrazeny proporce příspěvků s velmi vysokým sentimentem naprosto jednoznačně převažuje komunita *Everyday Feminism*. Uživatelé sledující *Catholic News Svc* vidí 31 % negativních<sup>22</sup> příspěvků na téma *potratu* a 69 % kladných příspěvků. Tyto hodnoty jsou stejné i pro náhodný výběr z celého Twitteru. Narozdíl od toho uživatelé sledující *Everyday Feminism* vidí 22 % negativních a 78 % pozitivních příspěvků.

Z výše prezentovaných výsledků je patrné, že narozdíl od skupin *Catholic News Svc*, *Only Mormons* a *LGBT foundation* jejichž obsah je v oblasti debaty nad tématem *potratu* naprosto vyvážený, komunita *Everyday Feminism* se k vyváženému obsahu přímo nedostává. Počet a hlavně rozdělení příspěvků na dané téma se výrazně liší od ostatních skupin i náhodného výběru z celého Twitteru. Můžeme tedy říct, že je postižena informační bublinou.

Někdo by mohl namítat, že rozdíl nebyl dostatečně markantní. Je však potřeba si uvědomit, že díky velké konektivitě uživatelů Twitteru je alespoň základní přístup k různým názorům snado zajištěn. Při hledání informační bubliny je tedy třeba pozorovat i zdánlivě malé rozdíly v rozdělení, nebo četnosti určitých

<sup>20</sup>Rozdíl je ve dvou řádech, proto se může stát, že malé modré sloupce zobrazující počty tweetů skupiny okolo *Catholic News Svc* nejsou dostatečně viditelné.

<sup>21</sup>V tomto případě se díváme na normalizovaný histogram. Na svislé ose tedy nejsou skutečné počty příspěvků s daným sentimentem vneseným na vodorovné ose. Místo toho je na svislé ose podíl tweetů s daným sentimentem a celkovým počtem tweetů ve sledované skupině. Toto zobrazení nám dovoluje studovat rozložení sentimentu dvou skupin, bez ohledu na rozdíl mezi absolutními počty příspěvků.

<sup>22</sup>Pod pojmem negativní příspěvek rozumněj takový tweet, který má hodnotu sentimentu menší než 0.5. Obdobně definujeme i pozitivní příspěvek.


příspěvků.

## 4.2 Klíčové slovo: Trump

Donald Trump, prezident Spojených států amerických, je v dnešní době sám o sobě velké téma snad všude na světě. Proto bylo předmětem jednoho z našich pozorování. Konkrétně jsme pozorovali, zda se nevyskytuje efekt informační bubliny v komunitě *biochemiků* okolo twitterové skupiny *BiochemSoc* a lidí zájímajících se o *těžbu ropy* sdružujících se okolo skupiny *PetroleumEcon*.

Měření probíhalo v době od 18.03.2017 10:20 do 18.03.2017 16:00. Dá se předpokládat, že kvůli prohlášením Donalda Trumpa o vědě a jeho postojům k těžbě ropy, bude komunita *biochemiků* zahlcována spíše negativními příspěvky, narozdíl od toho komunita okolo *těžby ropy* spíše pozitivními.

Z histogramu Obr. 4 vidíme, že naše očekávání nebyla správná. Počty tweetů u všech skupin, tj. *BiochemSoc*, *PetroleumEcon* a náhodného výběru z *Twitteru*, jsou řádově naprosto stejné. I samotné rozdělení sentimentu je totožné. Z výsledku můžeme usuzovat, že komunita okolo *BiochemSoc* je vystavena většímu počtu příspěvků na dané téma. Rozdíl je však velice nepatrný.



**Obrázek 4:** Histogramy počtu tweetů u skupin s klíčovým slovem „Trump“.

Narozdíl od našeho očekávání můžeme konstatovat, že skupiny *BiochemSoc* a *PetroleumEcon* jsou vystaveny dostatečně vyváženému obsahu na dané téma a nejsou tedy ohroženi informační bublinou. To je pravděpodobně způsobeno velkou konektivitou uživatelů Twitteru, která je spojuje s dostatečně velkým množstvím lidí opačných názorů, obdobně jako u tématu „*abortion*“.

## 5 Závěr

V první části práce jsme přiblížili problematiku informační bubliny, její dopady na společnost v makroskopickém měřítku a dosud provedené studie. Odtud jsme se přesunuli na technickou složku práce, kde jsme rozebrali veškeré detaily od stahování dat ze sociální sítě Twitter, přes aplikaci sentimentální analýzy v praxi až po samotnou konstrukci celého měření.

Jak jsme se v úvodu zmínili, cílem naší práce bylo vyvinutí metody, za pomoci které bychom mohli analyzovat míru postižení společnosti informační bublinou. Tohoto cíle jsme dosáhli, podařilo se nám vyvinout zmíněnou metodu, díky níž jsme prezentovali rozšíření informační bubliny na základě dat poskytovaných Twitterem. Výsledky měření dopadly navzdory naším předpokladům méně polarizovaně, než jsme očekávali, každopádně nevylučují/potvrzují naši hypotézu o míře filter bubble a různosti jejích efektů na vybranou část společnosti.

## Reference

- [1] ABADI, Martín, et al. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems*. (2015). arXiv:1603.04467. Dostupné také z: <https://arxiv.org/abs/1603.04467>
- [2] BARTHEL, Michael, Elisa SHEARER, Jeffrey GOTTFRIED a Amy MITCHELL. *The Evolving Role of News on Twitter and Facebook* [online]. In: . Pew Research Center, 2015 [cit. 2017-01-22]. Dostupné z: <http://www.journalism.org/2015/07/14/the-evolving-role-of-news-on-twitter-and-facebook/>
- [3] BIRD, Steven, Ewan KLEIN a Edward LOPER. *Natural language processing with Python*. Beijing: O'Reilly, 2009. ISBN 978-0-596-51649-9. Dostupné také z: <http://www.nltk.org/book/>
- [4] BOZDAG, Engin a Jeroen VAN DEN HOVEN. Breaking the filter bubble: democracy and design. *Ethics and Information Technology*. 2015, **17**(4), 249-265. DOI: 10.1007/s10676-015-9380-y. ISSN 1388-1957. Dostupné také z: <http://link.springer.com/10.1007/s10676-015-9380-y>
- [5] CHOLLET, François. *Keras*. GitHub 2015 [online]. [cit. 2017-01-22]. Dostupné také z: <https://github.com/fchollet/keras>
- [6] DAVIDSON, James, et al. The YouTube video recommendation system. *Proceedings of the fourth ACM conference on Recommender systems - RecSys '10*. New York, New York, USA: ACM Press, 2010. DOI: 10.1145/1864708.1864770. ISBN 9781605589060. Dostupné také z: <http://portal.acm.org/citation.cfm?doid=1864708.1864770>
- [7] DOSTÁL, Jakub. *FilterBubble-Twitter*. GitHub 2017 [online]. [cit. 2017-03-12]. Dostupné také z: <https://github.com/DostalJ/FilterBubble-Twitter>
- [8] GOLDBERG, Yoav a Omer LEVY. Word2vec Explained: deriving Mikolov et al.'s negative-sampling word-embedding method. *ArXiv: Computation and Language*. 2014. arxiv:1402.3722. Dostupné také z: <https://arxiv.org/abs/1402.3722>
- [9] GOTTRON, Thomas a Felix SCHWAGEREIT. The Impact of the Filter Bubble – A Simulation Based Framework for Measuring Personalisation Macro Effects in Online Communities. *ARXIV: Computer Science - Social and Information Networks*. 2016, **2016**. arXiv161206551G. Dostupné také z: <https://arxiv.org/abs/1612.06551#>
- [10] HILL, Aaron a Joshua ROESSLEIN. *Tweepy*. Github 2015 [online]. [cit. 2017-01-22]. Dostupné z: <https://github.com/tweepy/tweepy>
- [11] HUBERMAN, Bernardo A. Sociology of science: Big data deserve a bigger audience. *Nature*. 2012-2-15, **482**(7385), 308-308. DOI: 10.1038/482308d. ISSN 0028-0836. Dostupné také z: <http://www.nature.com/doifinder/10.1038/482308d>

- [12] LIAO, Q. Vera a Wai-Tat FU. Beyond the filter bubble: Interactive effects of perceived threat and topic involvement on selective exposure to information. *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems - CHI '13*. New York, New York, USA: ACM Press, 2013, 2359-2368. DOI: 10.1145/2470654.2481326. ISBN 9781450318990. Dostupné také z: <http://dl.acm.org/citation.cfm?doid=2470654.2481326>
- [13] LINDEN, G., B. SMITH a J. YORK. Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*. 2003, **7**(1), 76-80. DOI: 10.1109/MIC.2003.1167344. ISSN 1089-7801. Dostupné také z: <http://ieeexplore.ieee.org/document/1167344/>
- [14] KIM, Younghoon a Kyuseok SHIM. TWITOBİ: A Recommendation System for Twitter Using Probabilistic Modeling. *2011 IEEE 11th International Conference on Data Mining*. IEEE, 2011, , 340-349. DOI: 10.1109/ICDM.2011.150. ISBN 978-1-4577-2075-8. Dostupné také z: <http://ieeexplore.ieee.org/document/6137238/>
- [15] MATHIOUDAKIS, Michael a Nick KOUDAS. TwitterMonitor. *Proceedings of the 2010 international conference on Management of data - SIGMOD '10*. New York, New York, USA: ACM Press, 2010, **2010**, 1155-1158. DOI: 10.1145/1807167.1807306. ISBN 9781450300322. Dostupné také z: <http://portal.acm.org/citation.cfm?doid=1807167.1807306>
- [16] MCFARLAND, Daniel A., Kevin LEWIS a Amir GOLDBERG. Sociology in the Era of Big Data: The Ascent of Forensic Social Science. *The American Sociologist*. 2016, **47**(1), 12-35. DOI: 10.1007/s12108-015-9291-8. ISSN 0003-1232. Dostupné také z: <http://link.springer.com/10.1007/s12108-015-9291-8>
- [17] MIKOLOV, Tomas, Ilya SUTSKEVER, Kai CHEN, Greg CORRADO a Dean JEFF. Distributed Representations of Words and Phrases and their Compositionality. *Advances in Neural Information Processing Systems*. Curran Associates, 2013, (26), 3111-3119. Dostupné také z: <https://arxiv.org/abs/1310.4546>
- [18] PANG, Bo, Lillian LEE a Shivakumar VAITHYANATHAN. Thumbs up?: sentiment classification using machine learning techniques. *Proceedings of the ACL-02 conference on Empirical methods in natural language processing - EMNLP '02*. Morristown, NJ, USA: Association for Computational Linguistics, 2002, **2002**(10), 79-86. DOI: 10.3115/1118693.1118704. Dostupné také z: <http://portal.acm.org/citation.cfm?doid=1118693.1118704>
- [19] PAPACHARISSI, Zizi. Democracy online: civility, politeness, and the democratic potential of online political discussion groups. *New Media*. 2004, **6**(2), 259-283. DOI: 10.1177/1461444804041444. ISSN 1461-4448. Dostupné také z: <http://journals.sagepub.com/doi/10.1177/1461444804041444>
- [20] PARISER, Eli. (2011). *Beware online "filter bubbles"* [online]. Dostupné z [https://www.ted.com/talks/eli\\_pariser\\_beware\\_online\\_filter\\_bubbles](https://www.ted.com/talks/eli_pariser_beware_online_filter_bubbles)

- [21] PARISER, Eli. *The filter bubble: what the Internet is hiding from you*. New York: Penguin Press, 2011. ISBN 15-942-0300-8.
- [22] ROSENSTIEL, T., et al. Twitter and the News: How people use the social network to learn about the world. *American Press Institute: Insights, tools and research to advance journalism* [online]. 2015, **2015** [cit. 2017-01-22]. Dostupné z: <https://www.americanpressinstitute.org/publications/reports/survey-research/how-people-use-twitter-news/>
- [23] SANDERS, Niek. *Twitter Sentiment Corpus*. Sanders Analytics, 2011. Dostupné také z: <http://www.sananalytics.com/lab/twitter-sentiment/>
- [24] SEVERYN, Aliaksei a Alessandro MOSCHITTI. Twitter Sentiment Analysis with Deep Convolutional Neural Networks. *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval - SIGIR '15*. New York, New York, USA: ACM Press, 2015, **2015**, 959-962. DOI: 10.1145/2766462.2767830. ISBN 9781450336215. Dostupné také z: <http://dl.acm.org/citation.cfm?doid=2766462.2767830>
- [25] SHAH, D. V., J. N. CAPPELLA a W. R. NEUMAN. Big Data, Digital Media, and Computational Social Science: Possibilities and Perils. *The ANNALS of the American Academy of Political and Social Science*. 2015, **659**(1), 6-13. DOI: 10.1177/0002716215572084. ISSN 0002-7162. Dostupné také z: <http://ann.sagepub.com/cgi/doi/10.1177/0002716215572084>
- [26] TINATI, Ramine, Susan HALFORD, Leslie CARR a Catherine POPE. Big Data: Methodological Challenges and Approaches for Sociological Analysis. *Sociology*. 2014, **48**(4), 663-681. DOI: 10.1177/0038038513511561. ISSN 0038-0385. Dostupné také z: <http://journals.sagepub.com/doi/10.1177/0038038513511561>
- [27] Twitter, API Overview. *Twitter Developer Documentation* [online]. Twitter, 2016 [cit. 2017-01-22]. Dostupné z: <https://dev.twitter.com/overview/api>
- [28] University of Michigan, *UMICH SI650: Sentiment Classification*. University of Michigan SI650, 2011. Dostupné také z: <https://inclass.kaggle.com/c/si650winter11/data>
- [29] YOON, Kim. Convolutional Neural Networks for Sentence Classification. *ArXiv: Computation and Language*. arXiv, 2014. arXiv:1408.5882v2. Dostupné také z: <https://arxiv.org/abs/1408.5882>