

Středoškolská odborná činnost

Obor: 17. Filozofie, politologie a ostatní humanitní a společenskovědní obory

#filterbubble

Autoři: Františka Sandroni
Jakub Dostál

Olomouc 2017

Poděkování

Rádi bychom poděkovali Dott. Kvidu Sandroni za projevené pozorné připomínky během celé tvorby naší práce, každá sebemenší myšlenka nám byla cennou radou a podnětem ke zdokonalování studie. Velký dík patří také Barboře Pomykalové za grafickou úpravu. Neméně děkujeme Roswitě Chvátalové a Aleně Ambrožové, které se ochotně podílely na korektuře práce.

Prohlašujeme, že jsme tuto práci vypracovali samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů.

Prohlašujeme, že tištěná verze a elektronická verze soutěžní práce SOČ jsou shodné.

Nemáme závažný důvod proti zpřístupňování této práce v souladu se zákonem č. 121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon) v platném znění.

V Olomouci dne

.....

Title: #filterbubble

Authors: Františka Sandroni, Jakub Dostál

School: Slavonic grammar school Olomouc

Abstract:

Social networks are the most common source of the news and information nowadays. But their content is affected by *preferential algorithms*, which filter informations and lead user to bubble with homogenous opinions. This phenomenon is called *filter bubble* and can cause creation of radical groups.

We present new way to study filter bubble in online communities. Unlike most of the related work, our approach allows us to examine those effects precisely on social networks. *Sentimental analysis* is used to perform measurements of the content viewed by the *Twitter* users.

We present the power of our method on a several examples and show the ability of providing sociological results.

Keywords: filter bubble, social media, sentiment analysis, democracy, society

Název práce: #filterbubble

Autoři: Františka Sandroni, Jakub Dostál

Škola: Slovanské gymnázium Olomouc

Abstrakt:

Významným zdrojem informací v dnešní době jsou sociální sítě, jejich obsah je však ovlivěn *preferenčními algoritmy*. Ty filtrují informace a vedou jedince do situace, kdy je uzavřen v názorově homogenní bublině. Tomuto fenoménu se říká *filter bubble* a může zapříčinit například samovolný vznik extrémistických názorů a skupin.

V naší práci představujeme nový způsob studia informační bubliny na konkrétních online komunitách. Na rozdíl od mnoha předešlých studií nám umožňuje výzkum přímo v místě vzniku *informační bubliny*, tj. na sociálních sítích. Měření je založeno na *sentimentální analýze* příspěvků viditelných studovanými uživateli na *Twitteru*. To nám umožňuje odhadovat velmi přesně složení příspěvků v okolí velkého množství námi zvolených uživatelů.

Na několika příkladech jsme ukázali její funkčnost a schopnost podávat relevantní sociologické výsledky.

Naší prací se snažíme položit základní kámen studia *informační bubliny* pomocí matematiky, založeného na skutečných datech. Snažíme se otevřít dveře dalším i analytickým pohledům na tuto problematiku.

Klíčová slova: informační bublina, sociální sítě, Twitter, sentimentální analýza, společnost

Obsah

1	Co před námi internet skrývá	3
1.1	Filter bubble	3
1.2	Provedené studie	4
1.3	Problémy filter bubble	5
1.4	Výhody filter bubble	6
1.5	Preferenční algoritmy	6
2	Zpracování dat	8
2.1	Twitter	8
2.2	Data z Twitteru	9
2.3	Sentimentální analýza textu	9
2.4	Technické detaily sentimentální analýzy textu	10
3	Konstrukce měření	12
3.1	Sběr dat	12
3.2	Pozorování efektů informační bubliny	13
3.3	Výběr pozorovaných skupin	14
4	Diskuze měření	16
4.1	Klíčové slovo: Trump	16
4.2	Klíčové slovo: potrat	17
4.3	Diskuze	18
5	Závěr	20
	Reference	21

Úvod

Sociální sítě se čím dál více dostávají do popředí nejen jako volnočasové platformy pro různé aktivity, ale i jako informační kanály. V tomto ohledu se transformují ve zdroj aktuálních zpráv z celého světa bez ohledu na to, zda jde o novinku z uměleckých sfér, výsledky vědeckého zkoumání či seriózní informace z problematiky politických vztahů.

Aby uživatelé mohli sledovat jim imponující obsah, existují na sociálních sítích softwary umožňující filtraci uživatelem viděných příspěvků, nazývají se *preferenční algoritmy*. Personalizace informačního kanálu vytváří kolem uživatele okruh pro něj obsahově zajímavých příspěvků, což v důsledku může vést do situace, kdy je obklopován stále stejnými myšlenkami a názory. Tento fenomén byl nazván *filter bubble*, neboli *informační bublina* a je doposud nepříliš prozkoumaným jevem ve společnosti. Většina studií primárně pojímá filter bubble jako fenomén na úrovni sociologie a psychologie studující ho svými tradičními postupy.

Cílem naší práce je vyvinutí nové metody studia filter bubble, která by umožnila sledovat míru postižení konkrétních skupin ve společnosti. Abychom mohli informační bublinu studovat ve velkém měřítku, využijeme poznatků *machine learningu* aplikovaných na data poskytovaná sociální sítí Twitter. Tato data po pečlivé selekci zpracujeme a pomocí *sentimentální analýzy* ilustrujeme rozšíření informační bubliny napříč společností.

Potenciálem naší metody je její využití v sociologicko-žurnalistické sféře, kde by mohla pomoci řešit zásadní otázky v oblasti informovanosti společnosti a to také expanzi ideologických názorů.

1 Co před námi internet skrývá

Ve světě plném technického pokroku a masového používání internetu se snadno můžeme ztrácet v množství přijímaných informací. Nepřeborné množství zdrojů nás dennodenně zahlcuje spoustou nových zpráv, ať už na sociálních sítích či kdekoli jinde. Každá nově získaná informace rozšiřuje a formuje naše myšlenky. Co se však stane, získáváme-li stále stejné typy zpráv s obsahem podobným sobě navzájem?

Dostáváme se do tzv. *komnaty ozvěn*, jež nás stálým obklopováním a opakováním stejného názoru žene k radikalizaci nás samých z přesvědčení, že náš názor je ten nejlepší a také z důvodu, že ostatní jinak formulované náhledy na dané téma byly zcela přehlušeny.

Tento problém existuje odnepaměti, jen v jistých ohledech poněkud v jiném formátu. V minulosti nebyli lidé tak silně propojeni jako dnes, proto šíření informací probíhalo v mnohem menším měřítku.

Chodili do stejné hospůdky, navštěvovali jednoho mlékaře, znali jednu švadlenu. To je vedlo k přesvědčení, že právě jimi vybrané hospůdky, mlékaři i švadleny jsou těmi nejlepšími a postupy, jimiž se daní lidé řídili, byly jediným správným řešením. Prakticky nebylo ani jiného řešení, neboť v dosahu nebyl nikdo, kdo by je přesvědčil o opaku, a i kdyby se někdo takový vyskytl, nebyl by se svým novým odlišným stanoviskem přijat mezi komunitu lidí s identickým názorem.

Dnešní společnost není příliš odlišná od té výše popsané, jen nás a naše přesvědčení utváří sociální sítě jako například Facebook a Twitter, fungující na rychlém sdílení zpráv. Na jejich zdech sledujeme mnohé odkazy na komentáře, videa a články, formující se názory jedinců i davů, vznikající i zanikající politické myšlenky. Otázkou tedy zůstává, nakolik my sami jsme pohlceni vlastním přesvědčením v oboru a kde a jakým způsobem nás ovlivňují sociální sítě. Zda jsou tato samozvaná masmédia relevantní a kde mají své nedostatky, obzvláště v rovnoměrném šíření informací napříč společnostmi, se budeme zabývat dále.

1.1 Filter bubble

Filter bubble nebo také *informační bublina* je jedním z mnoha fenoménů dnešní doby. Jako první na ni upozornil a popsal ji Eli Pariser [23, 22]. Jde o jev vyskytující se na sociálních sítích, kdy uživatel každou online aktivitou¹ poukazuje na oblasti jeho zájmů, což může vést k vytváření obsahově homogenního prostoru při vyhledávání informací. Algoritmy snažící se usnadnit život pomocí personalizace viděných příspěvků se každou další činností uživatele zdokonalují. V konečném důsledku to znamená, že jsou to právě ony, jež rozhodují, co bude pro uživatele viditelné a co naopak konsekvencí prací algoritmů bude uživateli podáno v menší míře či úplně skryto [9]. Celkově to tedy může vést jedince do situace, kdy místo širokého spektra příspěvků na sobě obsahově nezávislých, vidí příspěvky pouze sobě navzájem podobné a sebe navzájem podporující. Veškeré tyto příspěvky v uživateli viděném kanálu podléhají velmi zúžené škále informací. Za takových okolností tvrdíme, že se uživatel nachází v informační bublině.

Jak se ukázalo v předešlé studii [9], filter bubble je velmi individuální a její efekt není u všech uživatelů zcela totožný. Míra filter bubble nezávisí pouze na

¹Tím rozumíme kliknutí, sdílení, komentování a obdobné činnosti.

obsahu viděných příspěvků, jak by se mohlo předpokládat, avšak na zdroji odkud informace čerpá. V důsledku můžeme pozorovat značně silnější efekt informační bubliny u uživatelů s mnoha konexemi na jiné uživatele, než u těch s menším rozsahem jejich spojení. Vycházíme-li z reálného prostředí, všimáme si, že jedinci s mnoha známostmi mají silnější postavení ve společnosti a tudíž i notný vliv na ostatní členy dané společnosti. Stejně tak je tomu na sociálních sítích. V situaci, kdy uživatel s mnoha konexemi na ostatní projeví svůj názor, příspěvkem či komentářem, je tu daleko větší pravděpodobnost ovlivnění značného množství uživatelů s ním spojených.

Informační bublina je velmi rozšířeným problémem, pokud si ji je však uživatel vědom, není filter bubble nepřekonatelnou bariérou v získávání relevantních informací.

1.2 Provedené studie

Jedna z velmi zajímavých studií [12] sleduje informační bublinu v uměle vytvořeném prostředí. Bylo vybráno dvacet osm účastníků, převážně studentů a univerzitních pracovníků, kteří byli náhodně rozděleni do dvou skupin. Všichni tito účastníci nejprve vyplnili formulář odhalující jejich dosavadní postoje k několika kontroverzním tématům za užití sémantického diferenciálu². K dosažení cíleného strachu a hrozby z tématu, byly příspěvky manipulovány například zvýrazňováním negativních slov.

Účastníci experimentu byli po týdnu požádáni o vyplnění formuláře a napsání krátké eseje na daná témata. K napsání eseje jim byla poskytnuta pozitivní i negativní fakta a *users opinions*. Z výsledku vyplynulo několik závěrů odhalujících samovolnou tvorbu filter bubble a to především samotným chováním účastníků.

Ukazují například, že přijímání názorů z různých úhlů pohledů závisí především na hloubce zájmu o dané téma. Čím vyšší je zájem o téma, tím vyšší je ochota přijímat protiargumenty, a naopak čím nižší je zájem o téma, tím nižší je ochota přijímat protiargumenty.

Jestliže se jedinec s nízkým povědomím o daném tématu dostane ke zdroji informací a není motivován hlubším podnětem jako jsou například blížící se volby, nevykazuje zájem o hledání relevantních faktů, nýbrž dává přednost vyhledávání *users opinion* nehlédě na zdroje, o které se *users opinion* opírá. Předložíme-li tedy současně jedinci informace podobné jeho již dříve získaným postojům a informace lišící se od jeho postoje, ve většině případů si vybere informace podobající se jeho stanovisku, avšak dostane-li se jedinec s nízkým povědomím do kritické situace³ a je motivován se v daném tématu vzdělávat, začíná vyhledávat informace podložené fakty, ať už podporující jeho stanovisko, či nikoliv.

Výše popsaná práce předkládá zajímavý pohled na problematiku informační bubliny, nemůžeme ji však použít na studie, při nichž bychom chtěli sledovat působení filter bubble na celou společnost, z důvodu malého počtu účastníků. Dalším negativem této práce je uměle vytvořené prostředí, ve kterém experiment probíhal, neboť nereflexuje reálné šíření informací napříč společností.

²Jedná se o velmi sofistikovanou psychologicky sociologickou metodu sloužící ke zjištění nuancí v postojích respondentů.

³Kupříkladu je-li jedinec postižen nějakou nemocí, je mnohem více motivován vyhledávat informace.

1.3 Problémy filter bubble

Vezmeme-li v úvahu, kolik času lidé tráví na sociálních sítích, můžeme usuzovat, že jejich názory a postoje se primárně vytvářejí zrovna zde [9, 12, 24]. Sleduje-li uživatel pouze názorově shodné příspěvky, mohla by informační bublina představovat značnou hrozbu demokratickým systémům, neboť uživatelům předkládá již vyfiltrované příspěvky a to zejména takové, jež by podpořily názor uživatele samotného, nikoli názor odlišný.

Opakovaný výběr již známého obsahu může jedince vést do *echo chamber*, kde tímto selektivním ziskem podobně motivovaných informací se utvrzuje ve svém původním názoru a naopak informace odlišné či opačné vytěsňuje do takové míry, že není schopen jejich dalšího vnímání.

Informační bublina může zapříčinit nemalé následky v makroskopickém měřítku na celou dnešní společnost v mnoha ohledech. V první řadě upozorníme na zjevné riziko, které se utváří při aktivních preferenčních algoritmech mezi uživateli sociálních sítí v demokratických společnostech. Zde i přes nabízenou diversitu obsahu uživatel opět vidí jen omezenou část. Autoři [4] vychází z konceptu, kde demokracie jako taková je rozdělena na liberální, deliberativní, republikánskou a agonistickou a pozorují, že každá z nich je ohrožena v jiné části její struktury. Problémy způsobené informační bublinou v liberální demokracii, jakožto ztráta povědomí občanů o různorodosti volby a nezávislosti médií, coby primárního zdroje informací občanů zvrhne upadajícího do rukou úzkého okruhu lidí, částečně řeší aplikace *Balancer*, *Scoopinion* či *Bobble*. Naopak u demokracie deliberativní můžeme považovat za následek působení filter bubble nedostatky v rovnocenné občanské diskusi, klesající toleranci vůči odlišným názorům a úbytek obecného přání zisku nových epistemických argumentů. U tohoto druhu demokracie byly vyvinuty aplikace *ConsiderIt*, *Opinion space*, které nás na základě sledování našich aktivit na sociálních sítích upozorňují na zdroje, ze kterých čerpáme informace nejvíce a také na ty, které pomíjíme.

Všechny zmíněné aplikace se snaží o minimalizaci vlivu informační bubliny na demokratické systémy, žádná však neřeší ohrožení v typech republikánské a agonistické demokracie.

Otázkou proto zůstává, jak dostatečně rozpoznat míru filter bubble a ochránit rozhled uživatele sociálních sítí bez ohledu na charakter demokracie, ve které se vyskytuje. Představme si živé předvolební období, kdy politické strany vytáhnou do boje a nebojí se použít žádných prostředků k potupě politických rivalů, kdy jedna aféra stíhá druhou, a na povrch vyplouvají rozličné skandály představitelů politických stran. Zároveň jsou také vypouštěny různé výstižné slogany rádo by řešící lokální i globální problémy. Čím více zaujatý slogan, tím masovější ovace. Začíná davové šílenství v podobě obrovských internetových diskusí v tématech, jež jsou pro uživatele klíčová. Vyhledáváním a připojováním se ke společenství se jedinec cítí být více informovaný, nicméně ztrácí přehled o celém tématu a zaměřuje se na čím dál menší okruh informací podporující jeho názor. Kamkoli se podívá a cokoli si přečte, je uspokojen, neboť vidí stále příspěvky podobné jeho názorům. Jak je dobře známo, uživatelé těchto internetových diskusí jsou často svým přesvědčením uchvázeni natolik, že ztrácí veškeré zábrany racionálně smýšlející osoby a své zaujaté názory se nebojí ukazovat široké veřejnosti [21]. Je-li však náhled na téma již ze začátku extremistický, kam až může zajít? Co když tyto podporované politické strany proklamující se všeobecnými předsudky nejsou

vhodnou volbou pro stát, ale díky svým hojně sdíleným příspěvkům oslovují více a více lidí, kteří dále šíří ideologii? Informační bubliny se z tohoto hlediska stávají problémem, i co se týče jejich etického vlivu na společnost.

1.4 Výhody filter bubble

Zkoumáme-li filter bubble jako celek a přestaneme-li se zaměřovat pouze na hrozby, které s sebou přináší, spatřujeme i pozitivní dopady. Kladné využití informační bubliny je zřejmé, zajímáme-li se o nějaké téma do hloubky a nehrozí ztráta objektivity jedince.

Vezměme si kupříkladu sportovního fanouška zaměřeného pouze na tenis. Neuvěřitelné množství existujících sportů a ještě větší počet příspěvků o nich dennodenně zaplavuje sociální sítě. Z tohoto jasně vyplývá, že kdyby fanoušek tenisu sledoval příspěvky ze všech odvětví sportů, ty o tenise by se mu zobrazovaly výrazně méně, tudíž by teoreticky mohlo dojít k omezení informovanosti ve středu zájmu daného fanouška. V takovém případě by nemusel zaregistrovat všechny výsledky posledních utkání, zprávy o kondici sportovců, či změnu času konání další akce, což by pro fanouška mohlo být rozhodující.

Stejně tak můžeme pozorovat pozitivní důsledky informační bubliny v podnikatelské sféře. Například takový vlastník restaurací potřebuje být plně informován o všech novinkách ve svém oboru vedoucích k vylepšení pracovních postupů. Nemálo může filter bubble pomoci, co se konkurenceschopnosti podnikatele týče. V situaci, kdy bude podrobně znát rozsah a celkovou nabídku služeb konkurentů, má mnohem větší šance uspět na trhu práce, což by s primárně zobrazovanými příspěvky o výsledcích šachových turnajů nebo průměrné spotřeby uhlí na jednu domácnost v jeho kanále informací rozhodně nedokázal tak snadno.

Jak vidno, informační bublina, pomineme-li negativní dopady na společnost popsané v předchozí podkapitole, není pouze hrozbou, ale může nám v mnoha ohledech usnadnit orientaci na sociálních sítích, ať jsme již fanoušky sportu, podnikateli, vědci, či kulturními nadšenci.

1.5 Preferenční algoritmy

Jak jsme již výše zmínili, personalizace obsahu, který vidíme na internetu, může být jak velkým problémem, tak velkou výhodou. Čemu jsme však dosud nevěnovali pozornost je, jak informační bubliny vznikají. Je zřejmé, že *Facebook*, *Twitter*, *YouTube* a podobní internetoví giganti shromažďují velké množství dat o našich internetových aktivitách. Méně jasné je, že to nedělají kvůli zlomyslným plánům na ovládnutí světa, nýbrž kvůli snaze zpříjemnit užívání jejich služeb⁴. Tato data poté pomocí moderních matematických a statistických metod užívají například k výběru obsahu, který nám bude co nejvíce imponovat, respektive k výběru obsahu, o kterém jsme se již dříve vyjádřili, že je pro nás zajímavý.

S obdobným přístupem se můžeme setkat při online nakupování [13], kde jsou nám doporučovány produkty obdobné těm, které jsme v poslední době hledali. Stejně tak například na *YouTube* [6], se dostaneme dříve k videím s podobným obsahem, jaký často sledujeme.

⁴Tím, že nám usnadní a zpříjemní jejich užívání, si zajistí větší návštěvnost, což je zdrojem jejich příjmů.

Metody, které se užívají pro sociální sítě a informační kanály [14], jsou většinou velmi sofistikované a opírají se o hluboké znalosti *machine learningu*, *statistiky* a *data miningu*. Velmi zjednodušeně řečeno, nový uživatel určité stránky je nejprve vystaven velmi širokému spektru informací. Někde na serveru provozovatele sítě sedí malá ne příliš chytrá umělá inteligence, která si zapisuje, na co uživatel kliká⁵. Své zápisky následně zpracovává a pomocí těchto zpracovaných poznámek následně odhaduje, co by se danému uživateli mohlo líbit.

⁵Samozřejmě také sleduje další způsoby hodnocení příspěvků, které jsou pro různé stránky odlišné. Na *Facebooku* například *like*, na *Twitteru* *retweet*.


2 Zpracování dat

S pokrokem v oblasti technologie probíhá i obrovský pokrok v oblasti čerpání zpráv a informací. Narozdíl od minulosti drtivá většina obyvatel vyspělých států má přístup k aktualitám v průběhu celého dne. Denní počet příspěvků na *Twitteru* dosahoval v roce 2010 neskutečných 6 milionů [15]. Je zřejmé, že není možné používat stejné postupy pro analýzu takto rozsáhlého množství dat jako dříve. Naštěstí se již nějakou dobu významným tempem posouvá i oblast *Big Data*, *Machine Learningu* a jejich podoblastí. Tyto obory nacházejí uplatnění téměř ve všech oblastech dnešní vědy [11] a stále větší pozornosti se jim dostává i v sociologii [28, 16, 27]. Právě proto jsme zvolili *Twitter* jako zdroj dat pro náš výzkum. Pomocí těchto dat se pokusíme popsat dynamiku *filter bubble* na sociálních sítích.

2.1 Twitter

Twitter je sociální síť se strukturou přátelských vztahů odlišnou od *Facebooku*. Uživatel si může navolit téměř libovolné množství lidí, jejichž příspěvky se mu budou zobrazovat. To však neznamená, že lidem, které si navolil, se budou zobrazovat jeho příspěvky.

Pro jednoduchost uveďme příklad. Pepa je nový uživatel *Twitteru*. Jeho kamarád ze školy se jmenuje Jiří a politik, kterého viděl včera ve zprávách a zamlouval se mu, má jméno Alois. Pepa začne *sledovat*⁶ jak Jiřího, tak Aloise. Od té chvíle uvidí všechny příspěvky, jak od spolužáka Jiřího, tak od politika Aloise. Za nějaký čas začne i Jiří *sledovat* Pepu. Od té chvíle i Jiří uvidí všechny Pepovy příspěvky. Politik Alois však Pepu nezná, proto ho *sledovat* nezačne, a tedy neuvidí příspěvky sdílené Pepou. Tyto vztahy jsou přehledně zobrazeny v grafu Obr. 1.



Obrázek 1: Znázorněné šipky směrem k vcholu *Pepa* ukazují ostatní uživatele, jimiž je *Pepa* ovlivněn. Je tedy patrné, že *Pepa* a *Jiří* vidí své příspěvky navzájem a navíc vidí i příspěvky *Aloisovi*. *Alois* však nevidí ani příspěvky *Pepy*, ani *Jiřího*, neboť příspěvky od těchto dvou uživatelů neproudí směrem k *Aloisovi*.

Takovouto strukturu můžeme chápat jako orientovaný graf, kde vrcholy představují uživatele *Twitteru* a orientované hrany mezi nimi proud příspěvků, tedy vztah *following*, neboli *sledující*. Pokud uživatele sleduje mnoho lidí, je směrem k němu připojeno více hran, mluvíme o uživateli s vysokou konektivitou nebo s

⁶Jde přímo o pojem *following* z této sociální sítě, něco jako *přátelství* na Facebooku.

vysokým stupněm. Obdobně uživatel, který má malou konektivitu, je takový, k němuž směřuje málo hran, je málo *sledován*.

Příspěvky na *Twitteru* mohou mít jakýkoliv textový tvar do délky 140 znaků, doplněný obrázkem nebo videem, mnohdy také hypertextovým odkazem na externí článek. Obrázky, videa, ani články na jiných stránkách nejsme schopni analyzovat. Plně však zkoumáme textovou část příspěvků. Ty bývají doplněné o tzv. *hashtagy*. To jsou slova nebo krátká spojení slov, před kterými stojí znak # (*křížek*). Z pravidla se jedná o slova, která jsou velmi aktuální, například různé reference na současné politické dění a podobně. Mnohdy jsou *hashtagy* užívány pouze pro zvětšení popularity příspěvku, jelikož častá forma vyhledávání je právě pomocí *hashtagu*.

2.2 Data z Twitteru

Právě data z *Twitteru* jsou pro nás velmi vhodná. Jak se ukazuje [2], narozdíl od *Facebooku*, Twitter užívá mnoho uživatelů jako zdroj informací a zpráv o aktuálním dění ve světě. Samozřejmě můžeme zpochybňovat validitu a přesnost informací, které se na takovýchto sítích objevují. Ať už jsou takovéto obavy oprávněné nebo ne, výzkum sociologických jevů, který v této práci provádíme, to nijak neovlivňuje.

Dalším důležitým důvodem, který vedl k výběru *Twitteru* jako média, ze kterého budeme stahovat informace, je snadná přístupnost k datům pomocí služby API poskytované přímo Twitterem [29]. Konkrétně pro naše účely jsme tuto službu nepoužívali přímo, ale za pomoci balíčku *tweepy* [10] pro programovací jazyk *python*. Ten umožňuje velmi snadné ovládání a filtrování proudu dat, které si vyžádáme z *Twitteru* a také jejich okamžitou analýzu a zpracování v *pythonu*.

2.3 Sentimentální analýza textu

Pro zpracování dat z *Twitteru* potřebujeme odhadnout sentiment jednotlivých tweetů. K tomu slouží *sentimentální analýza textu*, což je forma zpracování přirozeného jazyka⁷ [3]. V základní a nejvíce studované verzi tohoto problému se snažíme naučit počítač odhadnout, jestli je věta *positivní* či *negativní*. Existují samozřejmě i obdobné úlohy. Můžeme se zajímat o rozdíl mezi větami psanými *objektivně* a *subjektivně*, nebo rozlišovat více než dvě kategorie, například rozlišovat texty napsané *rozčileně*, *smutně*, *radostně* a *překvapeně*. Záleží pouze za jakým účelem problém řešíme a na datech, které máme k dispozici.

Sentimentální analýza textu se skládá z několika základních kroků, které jsou v obecném měřítku velmi podobné jiným machine learning algoritmům. Základem jsou data. V našem konkrétním případě se jedná přibližně o 1.5 miliónů tweetů⁸ v anglickém jazyce, které jsou označeny lidmi jako *positivní*, nebo *negativní*. Algoritmus, který používáme, je neuronová síť [26] obohacená o takzvané *word embedding* vrstvy a *convolution* vrstvy. Takovýto model je nejdříve "*natrénován*"⁹

⁷Pro pojem zpracování přirozeného jazyka budeme užívat převážně zkratku NLP z anglického názvu *Natural Language Processing*.

⁸Uspořádaných ve velkém datasetu složeném z několika menších [25, 30].

⁹Tréninkem je v této oblasti většinou myšlena optimalizace vhodné zvolené funkce, která odráží přesnost modelu.

na označených datech¹⁰. Poté je možné ho snadno používat pro predikci sentimentu z textu. Výstupem takového modelu je pravděpodobnost, že předložený text je pozitivní, tedy reálné číslo mezi 0.0 a 1.0. Takové číslo můžeme chápat jako míru positivity sentimentu textu. Tedy je-li tweet ohodnocen číslem 0.0, je zřejmé, že je negativní. Je-li ohodnocen číslem 0.5, chápeme ho jako neutrální. Text ohodnocený číslem 1.0 je jistě pozitivní.

Pokud řekneme, že při měření bylo zjištěno, že za určitou dobu bylo v určité skupině 40 % lidí proti a 60 % pro, je tím myšleno, že 40 % tweetů mělo sentiment menší než 0.5 a naopak 60 % větší než 0.5.

2.4 Technické detaily sentimentální analýzy textu

Pohlédneme-li do větších detailů algoritmu na odhad sentimentu, nejprve vytvoříme slovník s $V = 5000$ nejčastějšími slovy¹¹. Poté je každý datový bod, tedy každý *tweet*, transformován ze seznamu slov do seznamu *1-hot-encoding* vektorů¹².

Pro lepší představu uveďme triviální příklad. Mějme slovník o pěti slovech:

$$\begin{bmatrix} \text{les} \\ \text{mele} \\ \text{auto} \\ \text{maso} \\ \text{máma} \end{bmatrix}. \quad (2.1)$$

Jelikož slovo *auto* je ve slovníku na třetím místě, jeho *1-hot-encoding* reprezentace je „*auto*“ = $(0, 0, 1, 0, 0)$. Tedy vektor délky 5 s jedničkou na indexu, který odpovídá pořadí ve slovníku a nulami na všech ostatních indexech. Jeden tweet však není pouze jedno slovo. Více slov budeme vnitřně reprezentovat maticí, jejíž sloupce odpovídají jednotlivým slovům. Například věta „*Máma mele maso.*“ je reprezentována maticí:

$$\text{„Máma mele maso.“} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}. \quad (2.2)$$

Následuje *word embedding* vrstva [18, 8], která vytvoří novou reprezentaci slov. Ta je schopná mnohem lépe zachovávat semantické vlastnosti jednotlivých slov¹³. Vektory s velikostí $V = 5000$ transformuje do vektorů s velikostí $N = 32$,

¹⁰Data, u kterých označil jejich sentiment reálný člověk, považujeme za správná. I to je však relativní. Necháme-li více lidí ohodnotit ta stejná data, zjistíme, že ani lidé nejsou v hodnocení příliš konzistentní [20]. Pro naše účely je to však naprosto dostačující.

¹¹Toto číslo je jeden z tzv. *hyper parameters*, tedy parametr modelu, který volíme my sami tak, aby náš model měl co největší přesnost. Přitom užíváme spíše vlastní zkušenosti a uvážení.

¹²Kde každý vektor je reprezentací jednoho slova. Takové reprezentace mají velmi jednoduchý a zároveň velmi nepraktický tvar. Je-li slovo ve slovníku na k -té pozici, bude jeho *1-hot-encoding* reprezentací vektor plný nul, až na k -tou pozici, kde se bude nacházet číslo 1. Každé slovo je tedy reprezentováno vektorem o velikosti 5000. Je zřejmé, že tato reprezentace není příliš efektivní.

¹³Na takové reprezentaci slov můžeme sledovat zachování semantických vlastností a dokonce i možnost heuristického užití aritmetiky. Můžeme si všimnout, že například $\text{vec}(\text{France}) - \text{vec}(\text{Paris}) + \text{vec}(\text{Italy}) \approx \text{vec}(\text{Rome})$. Takové vlastnosti jsme při užití *1-hot-encoding* pozorovat nemohli.

které se mnohem lépe hodí pro zpracování a sentimentální analýzu, protože lépe reprezentují skutečný význam slov.

Na tuto vrstvu navazuje *convolution* vrstva [31], která je schopná prozkoumat postavení slov ve větě. Následuje *fully connected* vrstva, která slouží ke správné interpretaci vlastností odvozených neuronovou sítí, ukončená *relu aktivační jednotkou*. Ta se stará o dodání nelinearity do modelu, což zajišťuje přesnější klasifikaci. Úplně poslední je další plně propojená vrstva zakončená aktivační funkcí *sigmoid*, která se postará o transformaci na pravděpodobnost, pro snazší budoucí interpretaci.

Zdrojový kód pro sentimentální analýzu byl napsán v programovacím jazyce *pythonu*, za užití balíčků *TensorFlow* [1] a *Keras* [5].

3 Konstrukce měření

Sentimentální analýza textu nám umožňuje automaticky ohodnotit mírou sentimentu u velkého množství textových příspěvků. Výsledkem takového ohodnocení je však pouze reálné číslo mezi nulou a jedničkou. Proto odtud nevede žádná přímá cesta k měření síly informační bubliny na částech společnosti.


Uvažujeme-li konkrétního jedince ve společnosti, informační bublina není nijak explicitně závislá na něm samotném. Místo toho je až implicitně závislá na osobách, které tvoří obsah viditelný námi studovaným jedincem. Proto je zřejmé, že budeme-li chtít pozorovat sílu a efekt informační bubliny na konkrétního jedince, předmětem našeho studia musí být lidé v okolí tohoto jedince. V případě sociálních sítí to musí být konkrétně příspěvky, které tito lidé tvoří.

Jak jsme již zmiňovali v předešlých kapitolách, pro účely našeho výzkumu jsme využili sociální síť *Twitter*. Ta se v poslední době transformuje spíše do podoby informačního kanálu [2]. Neméně důležitý je fakt, že umožňuje poměrně snadný přístup k datům [10, 29].

3.1 Sběr dat

Naším cílem je pozorovat efekty a sílu informační bubliny na vybrané skupině ve společnosti. V odstavcích výše jsme však shrnuli, proč to není vůbec přímočarý proces.


Abychom vybrali určitou skupinu uživatelů *Twitteru* co nejpřesněji, využijeme existujících stránek, které sdružují příznivce hledané skupiny. Chceme-li například studovat, jak jsou informační bublinou postiženi *biochemici*, vybereme je z lidí, kteří sledují *Twitterový* profil *Biochemical Society*. Ten se po našem průzkumu *Twitteru* ukázal jako nejvíce populární účet s tímto tématem, sleduje ho přibližně 15 tis. lidí. Služby poskytované *Twitterem* na stahování dat nás bohužel omezují v počtu zkoumaných uživatelů, proto musíme ze všech 15 tisíc vybrat pouze část. Abychom zajistili náhodnost tohoto procesu, o výběr podmnožiny se stará jedna část softwaru [7], který jsme pro tyto účely vytvořili. Vybraná skupina sledovaných uživatelů je přehledně zobrazena na obrázku Obr. 2. Nyní máme vy-



Obrázek 2: *Twitter* vyobrazen jako množina, v níž je znázorněna skupina sledujících *Biochemical Society*. Z této skupiny bylo následně vybráno 100 náhodných uživatelů.

branou skupinu vzorků, na kterých chceme pozorovat efekty informační bubliny. Ta je však závislá na uživateli, kteří vytvářejí obsah viditelný studovanými

lidmi. To jsou ti uživatelé, které studované subjekty sledují. Vybereme několik *biochemiků*, na kterých chceme sledovat informační bublinu. Nyní musíme studovat obsah, který tvoří uživatelé sledování *biochemiky*. Vztah mezi sledovaným obsahem a studovanými uživateli je přehledně zobrazen na obrázku Obr. 3.



Obrázek 3: *Biochemici* znázornění jako skupina, k níž proudí příspěvky od uživatelů, které sledují. U těchto příspěvků sledujeme diversitu sentimentu jejich obsahu vůči vybraným tématům.

Pro přehlednost vyjádříme tyto vztahy matematicky. Je-li \mathbb{M}_{bio} množina všech uživatelů, kteří sledují stránku *Biochemical Society*, našim prvním úkolem je udělat náhodný výběr o velikosti n z této množiny. Tím vytvoříme podmnožinu \mathbb{P}_{bio} takovou, že obsahuje námi zvolený počet prvků $|\mathbb{P}_{bio}| = n$. Nyní pomocí služeb poskytovaných Twitterem vybereme množinu \mathbb{S}_{bio} takovou, že každý prvek je sledován alespoň jedním prvkem z \mathbb{P}_{bio} . Je-li \mathbb{T} množina všech uživatelů Twitteru a \mathbb{A} tzv. *adjacency matrix* celého Twitteru, tedy matice, pro kterou platí:

$$\mathbb{A}_{ij} = \begin{cases} 1, & \text{pokud } j \text{ sleduje } i; \\ 0 & \text{jinak.} \end{cases} \quad (3.1)$$

Potom $\mathbb{S}_{bio} = \{k \text{ takové, že } \exists l \in \mathbb{T} : \mathbb{A}_{kl} = 1 \wedge l \in \mathbb{P}_{bio}\}$.

3.2 Pozorování efektů informační bubliny

Na takto vybrané skupině lidí \mathbb{S}_{bio} , které sledují uživatelé, jejichž informační bublina nás zajímá, chceme pozorovat, zda jsou zaměřeni pouze jedním směrem a nepodávají dostatečně široké spektrum názorů. Umíme však pouze odhadnout sentiment jakéhokoliv *tweetu*.

Po dobu měření budeme stahovat všechny tweety, které vytvoří uživatelé z \mathbb{S}_{bio} , tedy lidé, které sledují subjekty našeho zájmu. Zajímají-li nás efekty filter bubble na *biochemiky*, budeme stahovat všechny tweety, které vytvoří lidé sledování *biochemiky*¹⁴.

Ze všech takto stažených tweetů vybereme pouze ty, které obsahují námi zvolené klíčové slovo. Mohli bychom použít například slovo „*Trump*“. Tím dostaneme pouze tweety, které se zabývají něčím ve vztahu k prezidentu *Trumpovi*. Pro každý takto vyfiltrovaný tweet provedeme sentimentální analýzu a tím odhadneme, zda

¹⁴Ve výsledku tedy budeme stahovat všechny tweety, které *biochemici* uvidí, což je právě náš záměr.

má autor pozitivní nebo negativní vztah k danému tématu. Provedeme-li takováto měření na dvou odlišných skupinách a stejném klíčovém slovu, tedy konkrétním tématu, můžeme odhadovat, kde působí informační bublina. Ať už téma podporuje, či nikoliv. Například můžeme porovnávat rozložení sentimentu zpráv s klíčovým slovem „Trump“, které vidí *biochemici* a *studenti pro Trumpa*. Můžeme předpokládat, že *biochemici* budou žít v bublině, která má více negativní názor na prezidenta Trumpa a *studenti pro Trumpa* naopak.

Člověku se může zdát, že tímto pouze pozorujeme názor, který mají *biochemici* na Trumpa. Tak to ale zdaleka není. Ve skutečnosti zkoumáme, jaké zprávy jsou viditelné *biochemikům*. A právě zprávy nimi viditelné jsou zdrojem informační bubliny, kterou chceme popisovat.

Zde je potřeba podotknout, že skupiny a klíčová slova se musí volit velmi pečlivě. Vybereme-li klíčové slovo „Islámský stát“ a pozorujeme sentiment, může dojít k velkému nedorozumění. Tweet, který hovoří o činech páchaných *Islámským státem*, bude jistě negativní. Problém však nastává v případě, kdy nějaký tweet hovoří například o vítězství nad *Islámským státem*. Text takového příspěvku se snadno může jevit jako pozitivní¹⁵, což bychom špatně vyhodnotili jako tweet podporující *Islámský stát*. Proto je potřeba jak pozorované skupiny tak klíčová slova volit velmi pečlivě.

V neposlední řadě zmiňme, že data stahovaná z Twitteru jsou již filtrována preferenčními algoritmy. Analyzované příspěvky jsou jen ty, které splňují námi zadané požadavky a zároveň se objevují na předních pozicích informačních kanálů sledovaných uživatelů¹⁶. Podotkneme, že toto chování je pro náš výzkum velmi užitečné, ne-li klíčové. Pokud bychom stahovali všechny příspěvky, i ty, které se objeví až ve velmi spodní části informačních kanálů, kde je již uživatel nemá šanci zaznamenat, nemohli bychom informační bublinu studovat.

3.3 Výběr pozorovaných skupin

Pro naše měření jsme provedli důkladný výběr studovaných objektů vycházející z nejaktuálnějšího politického dění, abychom dosáhli co nejpřesnějšího zachycení veškerých možných skupin názorů.

Z důvodu fungování naší metody v anglickém jazyce jsme nevolili témata lokální, kupříkladu z české politické sféry, jež by svým rozsahem a především jazykem nevyhovovala měření, nýbrž jsme zvolili témata globálního rozsahu řešící se na sociálních sítích zejména v anglickém jazyce.

Jako velmi rozporuplnou a politicky zajímavou veřejně známou osobností jsme vybrali nedávno zvoleného prezidenta Spojených států amerických Donalda Trumpa. Nynější prezident Trump byl již ve své předvolební kampani zastáncem radikálních změn, heslo „Make America Great Again“ a příslib zlepšení finanční situace musel velice imponovat nižší a střední třídě společnosti. Z tohoto důvodu se nám komunita *Students for Trump* zdála být optimální volbou, neboť jsou to obzvláště mladí lidé, kteří preferují radikálnější změny před těmi umírněnými.

¹⁵To však není problémem počítače, který text analyzuje. I člověk by radostný tweet o vítězství označil jako pozitivní.

¹⁶Vyvstává otázka, jak moc musí být příspěvek sdílený na to, aby byl považován za dostatečně známý a my ho analyzovali. O toto se automaticky starají preferenční algoritmy Twitteru [29], které jsou námi nastavené na úroveň *low*.

Jak se také Trump ve svých výrocích zmínil, hodlá snížit dotace na rozvoj vědy, proto usuzujeme, že právě vědecká společnost *biochemiků* bude mít názor na prezidenta Trumpa poněkud negativnější než názor *Student for Trump*. U těchto dvou skupin jsme proto vybrali jako klíčové slovo heslo „Trump“.

Námi druhé zvolené heslo „*abortion*“¹⁷ má také co dočinění s americkou politickou sférou. Trump se jako silný republikán s přáním stále rostoucího počtu amerických obyvatel vyjádřil velmi negativně o problematice potratu. Zmínil se o celoplošném zákazu potratů v USA, což vzbudilo v obyvatelstvu silné emoce, a to jak pozitivní, tak negativní.

Velký potenciál, co se týče příznivců potratů, jsme spatřovali v organizaci *Planned Parenthood*. Hlavním cílem této organizace je vzdělání v oblasti sexuální výchovy, ochrana jak právní, tak i zdravotní bez ohledu na finance daných osob, převážně žen v krizových situacích. Druhou námi sledovanou výraznou komunitou byla feministická skupina *Everyday Feminism*, jež tradičně podporuje rovnoprávnost žen ve všech sférách společnosti.

Na rozdíl od těchto dvou skupin potenciálních sympatizantů s potraty jsme vyhledali skupiny lidí s odlišnými etickými zásadami. Pro tyto účely byla zvolena komunita „*Abolish Abortion USA*“¹⁸, která se aktivně angažuje v problematice pozměnění ústavy, tedy zákazu potratů. Druhá skupina *Students for Life*, orientující se spíše proti potratům, se snaží o sexuální vzdělání mladých lidí pomocí přednáškových cyklů a školních akcí.

U těchto dvou skupin bychom mohli očekávat výsledky na téma potrat výrazněji odlišné, než u těch předchozích.

¹⁷Slovo, jež v angličtině znamená „*potrat*“.

¹⁸V doslovném překladu „*Zrušení potratů v USA*“.

4 Diskuze měření

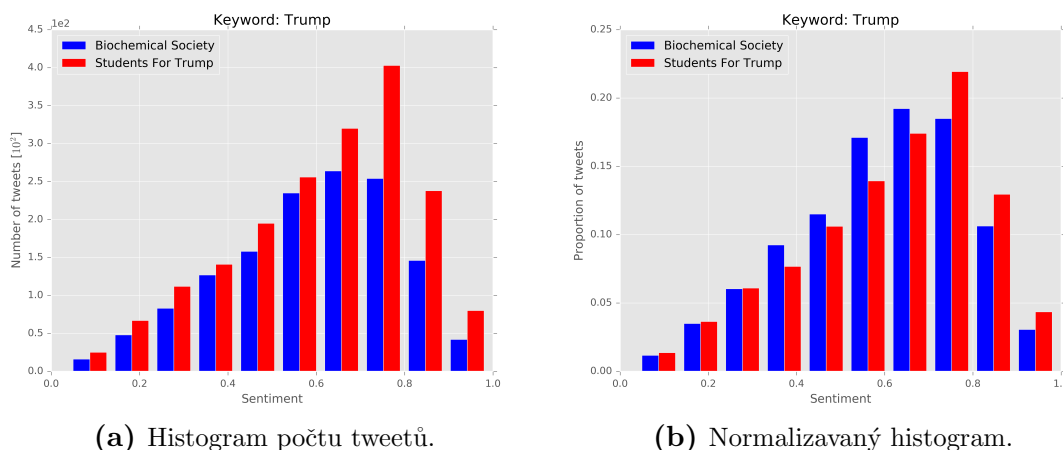
Pozorované skupiny jsme vybírali tak, abychom mohli pozorovat co nejsilnější efekty informační bubliny. Sledované komunity se tedy liší názorem na dané pozorované téma. Je klíčové pochopit, že našim cílem není ukázat to, že mají jiný názor. Cílem je prezentovat rozdílnost v příspěvcích, které na sociálních sítích členové komunit vidí. Pomocí našich výsledků poté okomentovat, jak moc je ohrožena objektivita uživatelů sociálních sítí.

4.1 Klíčové slovo: Trump

Donald Trump, prezident Spojených států amerických, je v dnešní době sám o sobě velké téma snad všude na světě. Proto byl předmětem jednoho z našich pozorování.

Pozorovali jsme, zda se nevyskytuje efekt informační bubliny v komunitě okolo twitterové skupiny *Biochemical Society* a lidí ze skupiny *Students For Trump*. Předpokládáme, že uživatelé sledující skupinu *Biochemical Society* se budou dostávat spíše k negativním příspěvkům s klíčovým slovem „Trump“. Naopak uživatelé ze *Students For Trump* budou mít, dle našich předpokladů, přístup spíše k pozitivním příspěvkům.

Na obrázcích Obr. 4 vidíme histogramy¹⁹ sentimentu příspěvků uvedených skupin. Měření probíhalo v době od 09.04.2017 16:15 (GMT+2) do 10.04.2017 14:45 (GMT+2).



Obrázek 4: Histogramy počtu tweetů s klíčovým slovem „Trump“.

Z histogramu Obr. 4(a) si nejprve všimněme, že uživatelé ze skupiny *Students For Trump* se dostávají k částečně většímu počtu tweetů, než uživatelé z druhé skupiny. I přes to je zde zřejmé, že větší počet příspěvků je způsoben převážně větším množstvím tweetů se sentimentem větším než 0.5, tedy pozitivních tweetů.

Abychom mohli prostudovat i rozložení sentimentu a nejenom počet příspěvků vztahujících se k danému tématu, pohlédneme na histogram Obr. 4(b), který

¹⁹Na svislé ose je v tomto případě počet nebo proporce příspěvků s příslušnou naměřenou hodnotou sentimentu, která je vyznačena na vodorovné ose. Toto zobrazení nám umožňuje snadno nahlédnout na rozdělení sentimentu v příspěvcích i na počty příspěvků s daným tématem.

zobrazuje normalizované²⁰ rozdělení dvou zmíněných skupin.

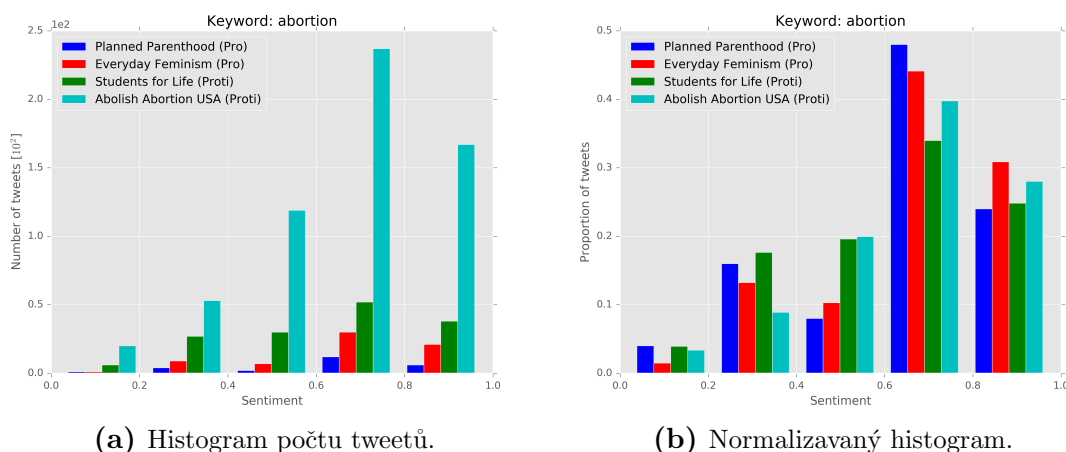
Při pohledu na Obr. 4(b) vidíme, že proporce tweetů s negativním sentimentem jsou větší u skupiny *Biochemical Society*, přesně podle našich očekávání. Relativní zastoupení pozitivních tweetů je naopak větší u skupiny *Students For Trump*, i když rozdíl není příliš výrazný.

Někdo by mohl namítat, že rozdíl nebyl dostatečně markantní. Je však potřeba si uvědomit, že díky velké konektivitě uživatelů Twitteru je alespoň základní přístup k různým názorům snadno zajištěn. Při hledání informační bubliny je tedy třeba pozorovat i zdánlivě malé rozdíly v rozdělení nebo četnosti určitých příspěvků.

Ukázali jsme existenci informační bubliny na poměrně jasném případě dvou skupin s opačným názorem na Donalda Trumpa. *Filter bubble* se projevila jak rozdílným počtem příspěvků na dané téma, tak rozdílným sentimentem jednotlivých příspěvků.

4.2 Klíčové slovo: potrat

Začneme s případem, kdy jsme se zabývali diversitou názorů na „potrat“. Hledali jsme příspěvky s klíčovým slovem „*abortion*“ a sledovali, zda se sentiment takovýchto příspěvků liší v různých skupinách²¹. Předpokládali jsme, že *Students for Life* a *Abolish Abortion USA* budou spíše proti potratům, jejich sentiment bude tedy spíše nižší. Na rozdíl od toho u *Planned Parenthood* a uživatelů sledujících *Everyday Feminism* jsme očekávali vyšší sentiment. Měření probíhalo v době od 06.04.2017 23:15 (GMT+2) do 07.04.2017 19:30 (GMT+2).



Obrázek 5: Histogramy počtu tweetů s klíčovým slovem „*abortion*“.

Ihned na první pohled jde z histogramu Obr. 5(a) vidět, že uživatelé ze skupiny *Abolish Abortion USA* jsou vystaveni tématu potratu mnohem více než,

²⁰V tomto případě se díváme na normalizovaný histogram. Na svislé ose tedy nejsou skutečné počty příspěvků s daným sentimentem vyneseny na vodorovné ose. Místo toho je na svislé ose podíl tweetů s daným sentimentem a celkovým počtem tweetů ve sledované skupině. Toto zobrazení nám dovoluje studovat rozložení sentimentu dvou skupin, bez ohledu na rozdíl mezi absolutními počty příspěvků.

²¹Konkrétně šlo o skupiny *Planned Parenthood*, *Everyday Feminism*, *Students for Life* a *Abolish Abortion USA*.

ostatní pozorované skupiny. A toto je jedním z nejdůležitějších znaků informační bubliny. Uživatel vystavený zvětšenému počtu příspěvků na dané téma má pocit, že společnost toto téma řeší velmi intenzivně. To však může být pouze klamné přesvědčení vzniklé působením *filter bubble*.

Opačný efekt vidíme u uživatelů skupiny *Planned Parenthood*, kteří vidí výrazně menší počet tweetů, než rovnocenné²² skupiny *Everyday Feminism* a *Students for Life*. Výrazně menší počet tweetů k danému tématu může obdobně vést k tomu, že je uživatel přesvědčen o nedůležitosti, nebo alespoň nezájmu společnosti k danému tématu.

Naše očekávání bylo, že u skupin, které neodporují potratům, tedy *Planned Parenthood* a *Everyday Feminism* uvidíme větší počet kladných tweetů, než u skupin, které se potratům snaží zabránit, tedy *Students for Life* a *Abolish Abortion USA*. Tato zákonitost není z Obr. 5(b) naprosto zřejmá. I přesto si lze povšimnout, že největší proporci tweetů se sentimentem větším než 0.5 mají právě skupiny *Planned Parenthood* a *Everyday Feminism*.

Prokázali jsme, že odlišné skupiny uživatelů Twitteru jsou v rámci tématu *potrat* vystaveny velmi odlišnému množství příspěvků na dané téma. Rozdíl v rozložení sentimentu není velký, ale i přesto částečně potvrzuje naše předpoklady.

Při měření s klíčovým slovem „*Trump*“ v kapitole 4.1 **Klíčové slovo: Trump** jsme ukázali ne příliš silný vliv informační bubliny. Narozdíl od toho při měření s klíčovým slovem „*abortion*“ se ukázal silný efekt filter bubble a to převážně u skupin zaměřených proti *potratu*. Tím jsme dokázali, že naše metoda schopná detekovat informační bublinu v konkrétních skupinách a tím podávat relevantní sociologické poznatky.

4.3 Diskuze

V předchozích částech jsme představili novou metodu [7] studia informační bubliny, kterou bychom chtěli zajistit přesnější a přímější měření tohoto efektu. V kapitole 4.2 **Klíčové slovo: potrat** jsme ukázali její sílu při odhalování informační bubliny. Samozřejmě má však své nedostatky, které se cítíme býti povinni sdělit.

Způsob, kterým vybíráme členy různých skupin, je založen na náhodném výběru uživatelů sledujících dominantní stránky sdružující uživatele s podobnými zájmy. Tato metoda může být velmi nespolehlivá hned z několika důvodů. Převážně je tomu třeba proto, že jistě existuje mnoho uživatelů, kteří stránku sledují a zároveň nejsou jejími přímými podporovateli. Bohužel jsme nepřišli na způsob, jak tomuto zabránit. Částečně tomu však předcházíme tím, že veškeré měření je na relativně velkém vzorku uživatelů. Proto stačí předpokládat, že statisticky významnější množství splňuje naše nároky, což není nijak nereálný předpoklad.

Někdo by mohl poukázat na to, že ve skutečnosti neměříme *filter bubble*, ale pouze sentiment příspěvků viditelných danou skupinou. Toto tvrzení je samozřejmě naprosto pravdivé. Je však třeba uvědomit si, že zatím nikdo nepřišel s dostatečně rozumnou mírou *informační bubliny*, není proto možné ji přímo měřit. Předmětem našeho měření je spíše původce *informační bubliny*.

Z kladných vlastností je jistě velmi podstatné to, že při použití naší metody je možné užití velkého množství vzorků. To kladně přispívá k rozeznávání šumu v datech od skutečně významných poznatků.

²²Rovnocenné ve smyslu téměř stejného počtu tweetů zabývajících se tématem potratu.

Dále jistě stojí za zmínku, že *filter bubble* měříme přímo v místě jejího výskytu a ne v uměle vytvořeném prostředí, jako většina z předchozích studií. Je nám také umožněno studium pouze v rámci určitého tématu.

Výzvou do budoucna bude jistě nalezení vhodné míry *informační bubliny*, která bude brát v úvahu jak rozdílný počet příspěvků, tak rozdílné rozložení sentimentu. K tomu by mohlo pomoci srovnávání jednotlivých skupin s náhodným výběrem z celého Twitteru.

Zřejmě existuje významná spojitost mezi *filter bubble* a tzv. *assortative mixing* [17, 19], kterou bychom v budoucnu rádi prozkoumali.

5 Závěr

V první části práce jsme přiblížili problematiku informační bubliny, její dopady na společnost v makroskopickém měřítku a dosud provedené studie. Odtud jsme se přesunuli na technickou složku práce, kde jsme rozebrali veškeré detaily od stahování dat ze sociální sítě Twitter, přes aplikaci sentimentální analýzy až po samotnou konstrukci celého měření.

Jak jsme se v úvodu zmínili, cílem naší práce bylo vyvinutí metody, za pomoci které bychom mohli analyzovat míru postižení společnosti *informační bublinou*. Tohoto cíle jsme dosáhli, podařilo se nám vyvinout zmíněnou metodu. Na několika příkladech jsme ukázali její funkčnost a schopnost podávat relevantní sociologické výsledky.

Novou metodu volně zpřístupňujeme, abychom umožnili její snadné užití ve výzkumu. Dále budeme provádět více měření a pokusíme se zmapovat postižení *informační bublinou* u vybraných témat. Výzvou je také nalezení vztahu mezi tzv. *assortative mixing* a *filter bubble*.

Při žádné části výzkumu nebylo nijak porušeno právo a soukromí žádného ze zkoumaných uživatelů.

Reference

- [1] ABADI, Martín, et al. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems*. (2015). arXiv:1603.04467. Dostupné také z: <https://arxiv.org/abs/1603.04467>
- [2] BARTHEL, Michael, Elisa SHEARER, Jeffrey GOTTFRIED a Amy MITCHELL. *The Evolving Role of News on Twitter and Facebook* [online]. Pew Research Center, 2015 [cit. 2017-01-22]. Dostupné z: <http://www.journalism.org/2015/07/14/the-evolving-role-of-news-on-twitter-and-facebook/>
- [3] BIRD, Steven, Ewan KLEIN a Edward LOPER. *Natural language processing with Python*. Beijing: O'Reilly, 2009. ISBN 978-0-596-51649-9. Dostupné také z: <http://www.nltk.org/book/>
- [4] BOZDAG, Engin a Jeroen VAN DEN HOVEN. Breaking the filter bubble: democracy and design. *Ethics and Information Technology*. 2015, **17**(4), 249-265. DOI: 10.1007/s10676-015-9380-y. ISSN 1388-1957. Dostupné také z: <http://link.springer.com/10.1007/s10676-015-9380-y>
- [5] CHOLLET, François. *Keras*. GitHub 2015 [online]. [cit. 2017-01-22]. Dostupné také z: <https://github.com/fchollet/keras>
- [6] DAVIDSON, James, et al. The YouTube video recommendation system. *Proceedings of the fourth ACM conference on Recommender systems - RecSys '10*. New York, New York, USA: ACM Press, 2010. DOI: 10.1145/1864708.1864770. ISBN 9781605589060. Dostupné také z: <http://portal.acm.org/citation.cfm?doid=1864708.1864770>
- [7] DOSTÁL, Jakub. *FilterBubble-Twitter*. GitHub 2017 [online]. Dostupné také z: <https://github.com/DostalJ/FilterBubble-Twitter>
- [8] GOLDBERG, Yoav a Omer LEVY. Word2vec Explained: deriving Mikolov et al.'s negative-sampling word-embedding method. *ArXiv: Computation and Language*. 2014. arxiv:1402.3722. Dostupné také z: <https://arxiv.org/abs/1402.3722>
- [9] GOTTRON, Thomas a Felix SCHWAGEREIT. The Impact of the Filter Bubble – a Simulation Based Framework for Measuring Personalisation Macro Effects in Online Communities. *ARXIV: Computer Science - Social and Information Networks*. 2016, **2016**. arXiv161206551G. Dostupné také z: <https://arxiv.org/abs/1612.06551#>
- [10] HILL, Aaron a Joshua ROESSLEIN. *Tweepy*. Github 2015 [online]. [cit. 2017-01-22]. Dostupné z: <https://github.com/tweepy/tweepy>
- [11] HUBERMAN, Bernardo A. Sociology of science: Big data deserve a bigger audience. *Nature*. 2012-2-15, **482**(7385), 308-308. DOI: 10.1038/482308d. ISSN 0028-0836. Dostupné také z: <http://www.nature.com/doifinder/10.1038/482308d>

- [12] LIAO, Q. Vera a Wai-Tat FU. Beyond the filter bubble: Interactive effects of perceived threat and topic involvement on selective exposure to information. *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems - CHI '13*. New York, New York, USA: ACM Press, 2013, 2359-2368. DOI: 10.1145/2470654.2481326. ISBN 9781450318990. Dostupné také z: <http://dl.acm.org/citation.cfm?doid=2470654.2481326>
- [13] LINDEN, G., B. SMITH a J. YORK. Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*. 2003, **7**(1), 76-80. DOI: 10.1109/MIC.2003.1167344. ISSN 1089-7801. Dostupné také z: <http://ieeexplore.ieee.org/document/1167344/>
- [14] KIM, Younghoon a Kyuseok SHIM. TWITOBİ: a Recommendation System for Twitter Using Probabilistic Modeling. *2011 IEEE 11th International Conference on Data Mining*. IEEE, 2011, , 340-349. DOI: 10.1109/ICDM.2011.150. ISBN 978-1-4577-2075-8. Dostupné také z: <http://ieeexplore.ieee.org/document/6137238/>
- [15] MATHIOUDAKIS, Michael a Nick KOUDAS. TwitterMonitor. *Proceedings of the 2010 international conference on Management of data - SIGMOD '10*. New York, New York, USA: ACM Press, 2010, **2010**, 1155-1158. DOI: 10.1145/1807167.1807306. ISBN 9781450300322. Dostupné také z: <http://portal.acm.org/citation.cfm?doid=1807167.1807306>
- [16] MCFARLAND, Daniel A., Kevin LEWIS a Amir GOLDBERG. Sociology in the Era of Big Data: The Ascent of Forensic Social Science. *The American Sociologist*. 2016, **47**(1), 12-35. DOI: 10.1007/s12108-015-9291-8. ISSN 0003-1232. Dostupné také z: <http://link.springer.com/10.1007/s12108-015-9291-8>
- [17] MCPHERSON, Miller, Lynn SMITH-LOVIN a James M COOK. Birds of a Feather: Homophily in Social Networks. *Annual Review of Sociology*. 2001, **27**(1), 415-444. DOI: 10.1146/annurev.soc.27.1.415. ISSN 0360-0572. Dostupné také z: <http://www.annualreviews.org/doi/10.1146/annurev.soc.27.1.415>
- [18] MIKOLOV, Tomas, Ilya SUTSKEVER, Kai CHEN, Greg CORRADO a Dean JEFF. Distributed Representations of Words and Phrases and their Compositionality. *Advances in Neural Information Processing Systems*. Curran Associates, 2013, (26), 3111-3119. Dostupné také z: <https://arxiv.org/abs/1310.4546>
- [19] NEWMAN, M. E. J. Mixing patterns in networks. *Physical Review E*. 2003, **67**(2). DOI: 10.1103/PhysRevE.67.026126. ISSN 1063-651x. Dostupné také z: <https://arxiv.org/abs/cond-mat/0209450>
- [20] PANG, Bo, Lillian LEE a Shivakumar VAITHYANATHAN. Thumbs up?: sentiment classification using machine learning techniques. *Proceedings of the ACL-02 conference on Empirical methods in natural language processing - EMNLP '02*. Morristown, NJ, USA: Association for Computational Linguistics, 2002, **2002**(10), 79-86. DOI: 10.3115/1118693.1118704. Dostupné také z: <http://portal.acm.org/citation.cfm?doid=1118693.1118704>

- [21] PAPACHARISSI, Zizi. Democracy online: civility, politeness, and the democratic potential of online political discussion groups. *New Media*. 2004, **6**(2), 259-283. DOI: 10.1177/1461444804041444. ISSN 1461-4448. Dostupné také z: <http://journals.sagepub.com/doi/10.1177/1461444804041444>
- [22] PARISER, Eli. (2011). *Beware online "filter bubbles"* [online]. Dostupné z https://www.ted.com/talks/eli_pariser_beware_online_filter_bubbles
- [23] PARISER, Eli. *The filter bubble: what the Internet is hiding from you*. New York: Penguin Press, 2011. ISBN 15-942-0300-8.
- [24] ROSENSTIEL, T., et al. Twitter and the News: How people use the social network to learn about the world. *American Press Institute: Insights, tools and research to advance journalism* [online]. 2015, **2015** [cit. 2017-01-22]. Dostupné z: <https://www.americanpressinstitute.org/publications/reports/survey-research/how-people-use-twitter-news/>
- [25] SANDERS, Niek. *Twitter Sentiment Corpus*. Sanders Analytics, 2011. Dostupné také z: <http://www.sananalytics.com/lab/twitter-sentiment/>
- [26] SEVERYN, Aliaksei a Alessandro MOSCHITTI. Twitter Sentiment Analysis with Deep Convolutional Neural Networks. *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval - SIGIR '15*. New York, New York, USA: ACM Press, 2015, **2015**, 959-962. DOI: 10.1145/2766462.2767830. ISBN 9781450336215. Dostupné také z: <http://dl.acm.org/citation.cfm?doid=2766462.2767830>
- [27] SHAH, D. V., J. N. CAPPELLA a W. R. NEUMAN. Big Data, Digital Media, and Computational Social Science: Possibilities and Perils. *The ANNALS of the American Academy of Political and Social Science*. 2015, **659**(1), 6-13. DOI: 10.1177/0002716215572084. ISSN 0002-7162. Dostupné také z: <http://ann.sagepub.com/cgi/doi/10.1177/0002716215572084>
- [28] TINATI, Ramine, Susan HALFORD, Leslie CARR a Catherine POPE. Big Data: Methodological Challenges and Approaches for Sociological Analysis. *Sociology*. 2014, **48**(4), 663-681. DOI: 10.1177/0038038513511561. ISSN 0038-0385. Dostupné také z: <http://journals.sagepub.com/doi/10.1177/0038038513511561>
- [29] Twitter, API Overview. *Twitter Developer Documentation* [online]. Twitter, 2016 [cit. 2017-01-22]. Dostupné z: <https://dev.twitter.com/overview/api>
- [30] University of Michigan, *UMICH SI650: Sentiment Classification*. University of Michigan SI650, 2011. Dostupné také z: <https://inclass.kaggle.com/c/si650winter11/data>
- [31] YOON, Kim. Convolutional Neural Networks for Sentence Classification. *ArXiv: Computation and Language*. arXiv, 2014. arXiv:1408.5882v2. Dostupné také z: <https://arxiv.org/abs/1408.5882>